



國立臺灣大學工學院應用力學研究所

碩士論文

Institute of Applied Mechanics

College of Engineering

National Taiwan University

Master's Thesis

應用深度學習分析敲擊回音時間域訊號

Analysis of Impact-Echo Time Signals by Deep Learning

林禹慶

Yu-Ching Lin

指導教授：劉佩玲 博士

Advisor: Pei-Ling Liu, Ph.D.

中華民國 113 年 7 月

July 2024

國立臺灣大學碩士學位論文

口試委員會審定書

MASTER'S THESIS ACCEPTANCE CERTIFICATE
NATIONAL TAIWAN UNIVERSITY

應用深度學習分析敲擊回音時間域訊號

Analysis of Impact-Echo Time Signals by Deep Learning

本論文係林禹慶 (R11543030) 在國立臺灣大學應用力學研究所完成之碩士學位論文，於民國 113 年 07 月 26 日承下列考試委員審查通過及口試及格，特此證明。

The undersigned, appointed by the Institute of Applied Mechanics on 26th July 2024 have examined a Master's Thesis entitled above presented by LIN, YU-CHING (student ID: R11543030) candidate and hereby certify that it is worthy of acceptance.

口試委員 Oral examination committee:

劉佩玲 劉佩玲 (指導教授 Advisor)

郭茂坤 郭茂坤

孫嘉宏 孫嘉宏

所長 Director: 陳國慶 陳國慶



誌謝

能夠順利完成這篇論文，我要感謝所有在過程中給予支持與幫助的人。

首先，由衷感謝我的指導老師劉佩玲教授，總是給予我不同的思考方式與想法，猶如一盞明燈，當在研究中感到徬徨時，指引我前行，使我能夠堅定地在研究的道路上繼續前進。

其次，我要特別感謝口試委員郭茂坤教授和孫嘉宏教授。兩位教授在口試過程中給予我寶貴的修改建議和研究方向，使我的論文得以更加完善。

此外，還要感謝結構安全評估研究室的每一位成員。學長姐們的寶貴經驗與無私分享，讓我們得以站在巨人的肩膀上，使研究過程更加順利。

最後，我要感謝一路上陪伴在我身邊的重要人們。感謝我的家人，他們是我的避風港，讓我能夠無後顧之憂的完成學業。感謝我的女朋友和她的家人，總是關心我在臺北的生活，並給予無盡的支持與鼓勵。還有感謝我的朋友們，他們的陪伴讓我在枯燥的研究之外，能享受最純粹的快樂。

即是無論什麼事，得之於人者太多，出之於己者太少。因為需要感謝的人太多了，就感謝天罷。






摘要

敲擊回音法是用於評估混凝土結構缺陷的非破壞檢測技術。透過敲擊產生應力波之位移響應具有週期性，利用傅立葉轉換後的頻率尖峰檢測缺陷深度。然而，淺裂縫的反射波容易受到表面波和模態干擾，導致頻譜中的尖峰頻率難以識別。隨著機器學習的發展，本研究利用深度學習模型直接判讀人工難以識別的時間域訊號，期望以新的方式分析裂縫深度。

本研究以數值模擬產出裂縫深度 6, 8, 10, 12, 14, 16, 18, 20, 22, 24, 26cm 之半無限域敲擊回音時間域訊號，作為深度學習模型之訓練集數據，輸入訊號時間長度 320 μ s（取樣間距 1.6 μ s，序列長度 200）。測試數據則是使用有底部反射影響之無限平版，其中包含不同試體厚度（30cm 與 20cm）裂縫深度與無裂縫試體。

本研究先進行多層感知器（MLP）、全卷積網路（FCN）、殘差網路（ResNet）和時間卷積網路（TCN）四種深度學習模型的比較，發現 TCN 模型能夠有效提取敲擊回音訊號特徵。

在進一步調整 TCN 模型架構時發現，卷積層過多或過少都無法獲得良好結果。卷積層太少無法有效提取訊號特徵，過多又會造成過擬合現象。卷積核大小會直接影響感知域，我們選擇的卷積核大小需要確保感知域至少大於輸入長度以獲得較好的結果。此外，增加卷積核數量可以提高模型的穩定性。最終我們的 TCN 模型採用 5 個殘差區塊、卷積核大小 8 且卷積核數量 25 作為最優模型架構。



由於實驗訊號不同於數值模擬訊號，會受雜訊、時間原點偏移及敲擊鋼珠大小的影響，故本研究嘗試在訓練集訊號加入雜訊、時間原點偏移，並增加不同尺寸的鋼珠敲擊源。經過數值模擬訊號測試後，發現在訓練集訊號中加入最大標準差為表面波振幅 3% 的雜訊，對時間原點作最大 $30\mu\text{s}$ 之平移，並使用 4, 6, 10mm 等多種鋼珠直徑進行敲擊，對於模型穩定性和泛用能力之提升表現最佳。此外，為處理實驗模型與數值模型波速不同所造成的波形差異，本研究也對實驗訊號依試體波速進行時間軸縮放，使深度學習模型可適用於不同波速試體。

本研究以有限平板的模擬訊號對優化過的 TCN 模型進行測試，發現該模型裂縫對深度經過訓練的訊號均表現優異，平均絕對誤差均 (MAE) 在 0.2cm 以下，對 6 至 26cm 的內插深度亦表現良好，MAE 在 0.3cm 以下，但對 4cm 和 30cm 的外插深度誤差較大。以實驗訊號測試之結果顯示，對於裂縫深度 6, 10, 12, 12-8, 14-6, 25cm 的判斷均表現良好，MAE 在 0.6cm 以下。在未使用濾波的情況下，模型都能有效判斷裂縫深度。此外，本研究也嘗試在訓練集中加入振幅縮放 (scaling)、振幅扭曲 (magnitude warping) 和時間扭曲 (time warping) 等資料增強技術，結果顯示這些技術對模型分析對實驗訊號的表現並無助益，尤其結果顯示尤其是時間扭曲會破壞訊號的時間關係，導致模型結果反而變差。

總結而言，本研究經過數值模擬訊號與實驗訊號的測試，TCN 模型確實能有效地分析敲擊回音時間域訊號，尤其對淺層裂縫的偵測更是遠優於頻率域方法，為混凝土結構之非破壞檢測提供了一種全新且有效的方法。

關鍵字：非破壞檢測、敲擊回音、時間序列、深度學習



Abstract

The impact-echo method is a widely used nondestructive technique for detecting defects in concrete structures. It generates stress waves and analyzes the resulting surface displacement response using Fourier transform to identify defects from peak frequencies in the spectrum. However, shallow cracks often produce reflections that are obscured by surface waves and modal interferences, making it difficult to accurately detect frequency peaks. With advancements in machine learning, this study explores the use of deep learning models to directly interpret time signals, aiming to provide a novel approach for analyzing crack depths.

This study utilizes numerical simulations to generate impact-echo time signals from a half-space with crack depths of 6, 8, 10, 12, 14, 16, 18, 20, 22, 24, and 26 cm as training data for deep learning models. The input signal duration is 320 μ s (sampling interval 1.6 μ s, sequence length 200). The test data consists of impact-echo signals from finite plates with bottom reflection influences, including specimens with crack depths and thicknesses of

30 cm and 20 cm, as well as intact specimens.



Initially, this study compared four deep learning models: multi-layer perceptron (MLP), fully convolutional network (FCN), residual network (ResNet), and temporal convolutional network (TCN). The findings revealed that the TCN model exhibited superior feature extraction capabilities for impact-echo signals.

Further optimization of the TCN model revealed that both too many and too few convolutional layers resulted in suboptimal performance. An insufficient number of layers failed to capture signal features effectively, while an excessive number led to overfitting. The chosen kernel size significantly influenced the receptive field, and it was crucial for the receptive field to exceed the input length for optimal results. Additionally, increasing the number of filters enhanced model stability. Our optimized TCN model employs 5 residual blocks with a kernel size of 8 and 25 filters.

Experimental signals, unlike numerical simulation signals, are influenced by noise, time shifts, and the diameter of the steel ball. This study attempts to enhance the training signals by incorporating noise, time shifts, and variations in steel ball diameter. Numerical simulation tests show that adding noise with a maximum standard deviation of 3% of the surface wave amplitude, time shifts up to 30 μ s, and using steel balls with diameters of 4, 6 and 10mm in the training data significantly improves the model's stability and

generalization ability. Additionally, to address waveform differences caused by varying wave velocities between experimental and numerical models, this study scales the time axis of experimental signals according to the specimen's wave velocity, thereby making the deep learning model applicable to specimens with different wave velocities.

The optimized TCN model was tested with finite plate simulation signals, showing excellent performance in predicting trained crack depths, with mean absolute errors (MAE) below 0.2cm. The model also performed well for interpolated depths of 6 to 26cm, with MAE below 0.3cm, but had larger errors for extrapolated depths of 4cm and 30cm. Testing with experimental signals showed good predictions for crack depths of 6, 10, 12, 12-8, 14-6, and 25cm, with MAE below 0.6cm. The model effectively determined crack depths even without filtering. This study also explored data augmentation techniques such as amplitude scaling, magnitude warping, and time warping in the training data. However, these techniques did not improve the model's performance in analyzing experimental signals; in fact, time warping particularly degraded the model's results by disrupting the temporal relationships in the signals.

In summary, this study demonstrates through tests with numerical simulation and experimental signals that the TCN model can effectively analyze impact-echo time signals, particularly excelling in detecting shallow cracks and significantly surpassing frequency

domain methods. This provides a novel and effective approach for the nondestructive testing of concrete structures.



Keywords: nondestructive testing, impact-echo, time series, deep learning



目次

誌謝	i
摘要	iii
Abstract	v
目次	ix
圖次	xiii
表次	xvii
第一章 緒論	1
1.1 研究背景	1
1.2 文獻回顧	2
1.3 章節簡介	3
第二章 敲擊回音法	5
2.1 彈性波傳基本原理	5
2.2 敲擊回音原理	6
2.3 彈性敲擊產生之應力	8
第三章 深度學習	11
3.1 多層感知器	11
3.2 全卷積網路	15
3.3 殘差網路	18

3.4	時間卷積網絡	20
第四章	模型架構	23
4.1	MLP	23
4.2	FCN	24
4.3	ResNet	24
4.4	TCN	25
4.5	共同設定	25
第五章	資料集	27
5.1	數值模擬訊號	27
5.1.1	數值模擬流程	27
5.1.2	數值模擬試體	30
5.2	實驗訊號	30
5.2.1	實驗設備	31
5.2.2	實驗試體	31
5.3	訊號輸入長度選取	37
5.4	訊號前處理	37
5.4.1	基本處理	37
5.4.2	資料增強	39
5.5	訓練集及測試集	42
第六章	結果與討論	45
6.1	模擬訊號結果	45
6.1.1	模型選擇	46
6.1.2	TCN 模型參數	47



6.1.3	雜訊影響	50
6.1.4	時間原點影響	52
6.1.5	鋼珠直徑影響	53
6.1.6	波速影響	55
6.1.7	模型泛用性測試	56
6.2	實驗訊號結果	63
6.2.1	濾波方式比較	63
6.2.2	資料增強比較	64
6.2.3	實驗結果	65
第七章	結論與未來展望	69
7.1	結論	69
7.2	未來展望	70
參考文獻		71







圖次

圖 1.1	裂縫深度 6cm 在時間域受模態干擾，且頻率域 33,333Hz 沒有明顯尖峰	2
圖 1.2	研究流程圖	4
圖 2.1	敲擊後應力波傳與位移週期響應示意圖	7
圖 3.1	多層感知器示意圖（兩層隱藏層）	11
圖 3.2	不同激勵函數輸出曲線	13
圖 3.3	具有三層結構的 MLP 對 $w_{13}^{(3)}$ 做偏導數	15
圖 3.4	LeNet-5 架構示意圖 [25]	16
圖 3.5	卷積層計算過程	16
圖 3.6	最大池化層計算過程	17
圖 3.7	FCN 架構示意圖 [32]	18
圖 3.8	在 CIFAR-10 資料集上更深的網路具有更高的訓練誤差以及測試誤差 [15]	19
圖 3.9	傳統結構與殘差區塊差別	19
圖 3.10	TCN 模型結構 (a) 擴張因果卷積，其中擴張因子 $d = 1, 2, 4$ ，卷積核大小 $k = 3$ 。(b) 殘差區塊架構。(c) TCN 殘差連接實際範例。[4]	22
圖 4.1	MLP 架構圖	23
圖 4.2	FCN 架構圖	24
圖 4.3	ResNet 架構圖	24
圖 4.4	TCN 架構圖	25
圖 5.1	鋼珠直徑所對應作用力時間圖	29
圖 5.2	量測波速示意圖	32

圖 5.3	量測波速之訊號	32
圖 5.4	實驗敲擊位置示意圖	33
圖 5.5	試體厚度 20cm 裂縫深度 6cm 實驗試體	34
圖 5.6	試體厚度 20cm 裂縫深度 10cm 實驗試體	34
圖 5.7	試體厚度 20cm 裂縫深度 12cm 實驗試體	35
圖 5.8	試體厚度 20cm 裂縫深度 12-8cm 實驗試體	35
圖 5.9	試體厚度 20cm 裂縫深度 14-6cm 實驗試體	36
圖 5.10	試體厚度 50cm 裂縫深度 25cm 實驗試體	36
圖 5.11	對實驗訊號進行基本處理過程 (a) 對實驗訊號進行濾波。(b) 判讀 訊號時間原點。(c) 對訊號重新取樣與正規化	38
圖 5.12	雜訊大小分布	40
圖 5.13	原始模擬訊號加入雜訊	40
圖 5.14	縮放係數大小	41
圖 5.15	原始模擬訊號進行縮放	41
圖 5.16	振幅扭曲曲線	41
圖 5.17	原始模擬訊號進行振幅扭曲	41
圖 5.18	時間步長扭曲曲線	42
圖 5.19	原始模擬訊號進行時間扭曲	42
圖 6.1	MLP、FCN、ResNet 與 TCN 訓練過程	46
圖 6.2	不同卷積核大小的模型表現	49
圖 6.3	不同卷積核數量的模型表現	50
圖 6.4	使用敲擊回音訊號測試集修改之 TCN 模型	50
圖 6.5	實際實驗訊號的雜訊	51
圖 6.6	訓練資料加入雜訊對不同雜訊大小的測試結果	51
圖 6.7	模擬訊號與實驗訊號時間原點差異	52
圖 6.8	訓練資料加入平移對不同平移大小的測試結果	53
圖 6.9	4mm 鋼珠敲擊裂縫深度 6 ~ 16cm 與 18 ~ 26cm 無限平版結果	54
圖 6.10	6mm 鋼珠敲擊裂縫深度 6 ~ 16cm 與 18 ~ 26cm 無限平版結果	54
圖 6.11	10mm 鋼珠敲擊裂縫深度 6 ~ 16cm 與 18 ~ 26cm 無限平版結果	54
圖 6.12	不同直徑鋼珠在裂縫深度 12cm 時間域與頻率域模擬訊號	55

圖 6.13 修正混凝土波速前與後	56
圖 6.14 試體厚度 30cm 裂縫深度 6 ~ 26cm 無限平版結果 (MAE: 0.152)	57
圖 6.15 試體厚度 20cm 裂縫深度 6 ~ 17cm 無限平版結果 (MAE: 0.138)	57
圖 6.16 試體厚度 6 ~ 26cm 無裂縫無限平版結果 (MAE: 0.347)	58
圖 6.17 試體厚度 30cm 裂縫深度 4cm 無限平版結果 (MAE: 2.021)	59
圖 6.18 試體厚度 30cm 無裂縫無限平版結果 (MAE: 3.630)	59
圖 6.19 裂縫深度 4cm 與無裂縫厚度 30cm 與其他深度比較	59
圖 6.20 試體厚度 20cm 裂縫深度 6cm 有限平版整體結果	61
圖 6.21 試體厚度 20cm 裂縫深度 10cm 有限平版整體結果	61
圖 6.22 試體厚度 20cm 裂縫深度 6cm 有限平版截面結果	61
圖 6.23 試體厚度 20cm 裂縫深度 10cm 有限平版截面結果	61
圖 6.24 試體厚度 20cm 裂縫深度 12-8cm 有限平版整體結果	62
圖 6.25 試體厚度 20cm 裂縫深度 14-6cm 有限平版整體結果	62
圖 6.26 試體厚度 20cm 裂縫深度 14-6cm 有限平版截面結果	62
圖 6.27 試體厚度 20cm 裂縫深度 14-6cm 有限平版截面結果	62
圖 6.28 試體厚度 20cm 裂縫深度 6cm 實驗結果 (MAE: 0.534)	65
圖 6.29 試體厚度 20cm 裂縫深度 10cm 實驗結果 (MAE: 0.431)	65
圖 6.30 試體厚度 20cm 裂縫深度 12cm 實驗結果 (MAE: 0.399)	66
圖 6.31 試體厚度 20cm 裂縫深度 12-8cm 實驗結果 (MAE: 0.437)	66
圖 6.32 試體厚度 20cm 裂縫深度 14-6cm 實驗結果 (MAE: 0.595)	66
圖 6.33 試體厚度 50cm 裂縫深度 25cm 實驗結果 (MAE: 0.545)	66
圖 6.34 試體厚度 20cm 裂縫深度 6cm 實驗整體結果	67
圖 6.35 試體厚度 20cm 裂縫深度 10cm 實驗整體結果	67
圖 6.36 試體厚度 20cm 裂縫深度 6cm 實驗截面結果	67
圖 6.37 試體厚度 20cm 裂縫深度 10cm 實驗截面結果	67
圖 6.38 試體厚度 20cm 裂縫深度 12-8cm 實驗整體結果	68
圖 6.39 試體厚度 20cm 裂縫深度 14-6cm 實驗整體結果	68
圖 6.40 試體厚度 20cm 裂縫深度 12-8cm 實驗截面結果	68
圖 6.41 試體厚度 20cm 裂縫深度 14-6cm 實驗截面結果	68





表次

表 5.1	材料參數	29
表 5.2	鋼珠直徑所對應接觸時間	29
表 5.3	模擬試體資訊	30
表 5.4	實驗試體資訊	32
表 5.5	實驗試體物理性質	33
表 5.6	所有訓練集資訊	43
表 5.7	所有測試集模擬訊號資訊	44
表 5.8	所有測試集實驗訊號資訊	44
表 6.1	依照裂縫深度選擇鋼珠直徑之訓練集資訊	45
表 6.2	使用與訓練集相同深度之測試集資訊	45
表 6.3	MLP、FCN、ResNet 與 TCN 訓練與測試結果	47
表 6.4	卷積層深度	48
表 6.5	卷積核大小	49
表 6.6	卷積核數量	50
表 6.7	不同波速材料性質	56
表 6.8	使用所有鋼珠直徑之訓練集資訊	56
表 6.9	內插深度測試集資訊	57
表 6.10	外插深度測試集資訊	59
表 6.11	有限平版測試集資訊	60
表 6.12	裂縫中心附近實驗測試集資訊	63
表 6.13	濾波方法對實驗訊號結果	64
表 6.14	資料增強方法對實驗訊號結果	65
表 6.15	整體實驗試體測試集資訊	67





第一章 緒論

1.1 研究背景

非破壞檢測 (nondestructive testing, NDT) 能在不破壞結構完整性與安全性的情況下，檢測結構物內部的缺陷。敲擊回音法在混凝土結構檢測中廣泛使用，主要利用暫態彈性波的波傳原理。當應力波在檢測試體內部傳遞時，會在邊界或缺陷處產生繞射、折射與反射現象。位移感測器接收的表面位移訊號經過快速傅立葉轉換 (fast Fourier transform, FFT) 後，將時間域的位移訊號轉換為頻率域訊號，即可透過頻譜上的能量變化判斷試體的厚度或缺陷的深度。

敲擊回音法主要使用 FFT 將訊號轉換成頻率域，或使用短時傅立葉轉換 (short-time Fourier transform, STFT)、小波轉換 (wavelet transform, WT) 等時頻分析方法來判讀裂縫資訊。然而，淺層裂縫的反射容易受到表面波及模態干擾影響，造成實際上在頻率域難以明確判讀其能量尖峰，如圖 1.1 所示。

近年來隨著圖形處理器 (GPU) 的性能和平行計算能力的強化，研究團隊能設計出更加深層與複雜的類神經網路架構，且利用 GPU 運算可以大幅縮短訓練時間。這些進步不僅提升了模型訓練的效率，同時也促進了深度學習的快速發展。因此，本研究希望能夠使用深度學習模型處理人工難以解讀的時間域訊號，嘗試以新的方式分析裂縫深度。




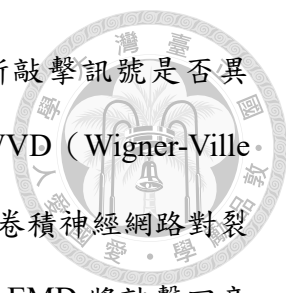
圖 1.1 裂縫深度 6cm 在時間域受模態干擾，且頻率域 33,333Hz 沒有明顯尖峰

1.2 文獻回顧

敲擊回音法檢測混凝土是一項相當成熟的技術。Sansalone 與 Carino 對橋面、樓板、牆壁等混凝土結構物進行檢測並進行頻率域的分析 [7, 41]；而 Lin 與 Sansolone 則是對樑、柱與基樁等桿狀混凝土結構物等結構物內部的裂縫、孔隙與蜂窩進行檢測 [29, 30]。除此之外，也有研究使用不同的時頻分析方法來改進敲擊回音訊號的判讀。Yeh 與 Liu 透過 STFT、WT[51]；而 Lin 等人則利用經驗模態分解（empirical mode decomposition, EMD）進行的希爾伯特-黃轉換（Hilbert-Huang transform, HHT）[27]，這些方法對於敲擊回音訊號的判讀有重要的幫助。

儘管敲擊回音的頻率域與時頻分析已經有許多相關研究，然而這些傳統方法仍然需要專業人員的判斷，增加了操作的難度與門檻。因此，本研究希望能利用人工智慧來協助判讀，取代傳統的人為檢測方式。早期 Pratt 與 Sansalone 的研究就已經使用類神經網路與敲擊回音的能量頻譜特徵進行訓練並預測裂縫深度 [37]，但模型的準確性與特徵選取高度相關。

隨著深度學習的發展，現今模型能夠自動從數據中提取重要特徵，也擴展了敲擊回音的應用範圍。林昀儒利用格拉姆角場（gramian angular field, GAF）處



理敲擊回音訊號，並結合自動編碼器（autoencoder, AE）判斷敲擊訊號是否異常 [55]。陳源泰使用 YOLO 深度學習模型來辨識敲擊回音 WVD（Wigner-Ville distribution）時頻圖中的表面波、回音與震動 [58]。陳柏合使用卷積神經網路對裂縫及鋼筋敲擊回音訊號的雙譜頻譜進行分類 [57]。謝承展應用 EMD 將敲擊回音訊號分解成多個本質模態函數（intrinsic mode function, IMF），並利用一維卷積神經網路對表面波、回音和震動進行分類 [56]。張亘利用卷積神經網路對裂縫和鋼筋敲擊回音訊號的 WT 時頻圖進行分類並判斷深度 [53]。曾勁凱運用深度頻譜斷層掃描法結合 AE 來標記裂縫區域 [54]。

敲擊回音訊號屬於時間序列資料，而時間序列分類（time series classification, TSC）是這方面研究的重要領域之一 [3, 11, 19, 20]。隨著卷積神經網路（convolutional neural network, CNN）在電腦視覺領域取得了重大突破 [24]，這也推動了其在 TSC 任務上的應用 [49]。時間序列外部回歸（time series extrinsic regression, TSER）需要理解時間序列與外在變數之間關係，輸出連續數值而非分類標籤，是 TSC 的對應方法。例如，TSC 可能將心電圖（electrocardiogram, ECG）信號分類為心律不整或正常，而 TSER 則透過 ECG 信號來預測心率或呼吸頻率 [35, 36]。

1.3 章節簡介

本論文分為七個章節：第一章簡述研究背景與動機；第二章介紹敲擊回法原理；第三章介紹深度學習架構原理；第四章說明本文使用的深度學習模型；第五章詳述本次研究使用的資料集；第六章討論訓練模型後的結果；第七章總結研究結果與其未來發展方向。




圖 1.2 研究流程圖



第二章 敲擊回音法

敲擊回音法是 Sansalone 與 Carino 提出用於評估混凝土結構缺陷的 NDT 技術 [41]。透過機械敲擊產生低頻的應力波能在非均質材料中傳播，改善超音波檢測中高頻波傳播能量衰減過快，以及高頻波在骨材、氣孔和鋼筋產生反射波干擾真實缺陷訊號辨識的限制。以下介紹敲擊回音法的原理。

2.1 彈性波傳基本原理

當一均質、等向的半無限域彈性體表面受到撞擊時，會在敲擊點附近產生暫態應力波並向外傳遞。這些應力波包括從敲擊點向試體內部傳遞且速度最快的縱波（primary wave）和次快的橫波（secondary wave），以及以敲擊點沿著試體表面傳遞且速度最慢的表面波（surface wave）。

應力波波速與彈性體的楊氏模數 E 、柏松比 ν 及密度 ρ 等材料性質有關：

$$C_p = \sqrt{\frac{E(1-\nu)}{\rho(1+\nu)(1-2\nu)}} \quad (2.1)$$

$$C_s = \sqrt{\frac{E}{2\rho(1+\nu)}} \quad (2.2)$$

其中 C_p 表示縱波波速（m/s）， C_s 表示橫波波速（m/s）， E 表示楊氏模數（Pa）、 ν 表示柏松比， ρ 表示密度（kg/m³）。

根據雷利方程式 (Rayleigh equation)，表面波速 C_r 與橫波波速 C_s 及縱波波速 C_p 有關，如式 (2.3) 所示。而雷利方程式又可以由經驗公式求得表面波波速。如式 (2.4) 所示 [1]。

$$\left(2 - \frac{C_r^2}{C_s^2}\right)^2 = 4\sqrt{\left(1 - \frac{C_r^2}{C_p^2}\right)\left(1 - \frac{C_r^2}{C_s^2}\right)} \quad (2.3)$$

$$C_r = \frac{0.87 + 1.12\nu}{1 + \nu} C_s \quad (2.4)$$

當應力波傳遞時遇到不同介質，會產生折射波與反射波。假設應力波由介質 1 入射到介質 2 時，入射波、折射波與反射波振幅的關係式如下。

$$\begin{cases} A_{\text{refracted}} = \frac{2Z_2}{Z_2 + Z_1} A_{\text{incident}} \\ A_{\text{reflected}} = \frac{Z_2 - Z_1}{Z_2 + Z_1} A_{\text{incident}} \end{cases} \quad (2.5)$$

$$\begin{cases} A_{\text{refracted}} = \frac{2Z_2}{Z_2 + Z_1} A_{\text{incident}} \\ A_{\text{reflected}} = \frac{Z_2 - Z_1}{Z_2 + Z_1} A_{\text{incident}} \end{cases} \quad (2.6)$$

其中 A_{incident} 表示入射波振幅， $A_{\text{refracted}}$ 表示折射波振幅， $A_{\text{reflected}}$ 表示反射波振幅， Z_1 表示介質 1 之聲阻抗 ($\text{kg}/(\text{m s}^2)$)， Z_2 表示介質 2 之聲阻抗 ($\text{kg}/(\text{m s}^2)$)。

而將反射波振幅除以入射波振幅，可得到反射係數 Γ 如式 (2.7) 所示。

$$\Gamma = \frac{Z_2 - Z_1}{Z_2 + Z_1} \quad (2.7)$$

由上述振幅關係式可以知道，當 $Z_1 > Z_2$ 時反射波振幅與入射波振幅同號，反之 $Z_2 > Z_1$ 時反射波振幅則與入射波振幅異號。

2.2 敲擊回音原理

敲擊回音法是透過敲擊後產生之縱波、橫波與表面波的波傳行為進行分析。

當位移感測器與敲擊點位置靠近時，感測器主要接收速度最快的縱波以及縱波的

反射波訊號，因此敲擊回音法主要是分析縱波之傳遞行為。由於感測器接收的時間域訊號通常只能觀測出縱波之首達波與表面波，而重要缺陷資訊主要由能量較小的反射波、繞射波傳遞，造成訊號容易混疊，也增加辨識的困難程度。因此敲擊回音法利用 FFT 將時間域訊號轉為頻率域訊號，並以此找出反射波的頻率特徵。

當敲擊產生應力波，其縱波會以壓應力形式傳遞。根據式 (2.7)，當波從聲阻抗大的介質傳遞至聲阻抗小形式的介質，如同從混凝土傳遞至聲阻抗小缺陷或試體底部的空氣時，縱波會以入射波相反的張應力形式反射。當反射的張力波再次回到試體表面的空氣時，它會再次以相反的壓應力形式反射，這個過程會不斷重複，直到能量衰減到幾乎消失。




圖 2.1 敲擊後應力波傳與位移週期響應示意圖

以圖 2.1 為例，可以得知縱波在試體表面產生之位移響應具有週期性，此週期性位移在 FFT 頻譜分析會出現極大值。已知縱波從頂端行進至底部之路徑長為 D ，波傳遞一個週期的路徑長即是試體厚度兩倍也就是 $2D$ ，因此該尖峰頻率 f 可依式 (2.8) 計算獲得。

$$f = \frac{1}{\Delta t} = \frac{C_p}{2D} \quad (2.8)$$

其中 f 表示縱波反射介面為空氣之頻率 (Hz)， C_p 表示縱波波速 (m/s)， D 表示試體表面到底部的距離 (m)。



2.3 彈性敲擊產生之應力

不同敲擊源形成之應力波會造成不同的位移響應。使用尺寸過大的敲擊源檢測淺層裂縫時，會因撓曲振動過大影響訊號；而尺寸過小的敲擊源檢測深層裂縫時，則因為應力波能量不足，難以獲得有效回音訊號。

根據 Hertz 的接觸理論，當兩個接觸體都為均質、等向之線彈性體接觸時會滿足以下式 [16]：

$$F = k_2 \alpha^{\frac{2}{3}} \quad (2.9)$$

其中 F 代表接觸力， k_2 代表彈性體材料性質相關常數， α 代表接觸表面相對位移。 α 被近似為式 (2.10)，力與時間關係被近似為式 (2.11) [13]。

$$\alpha = \alpha_m \sin \left(\frac{1.068 v_0 t}{\alpha_m} \right) \quad (2.10)$$

$$F = \frac{1.140 v_0^2}{k_1 \alpha_m} \sin \left(\frac{1.068 v_0 t}{\alpha_m} \right) = F_{\max} \sin \left(\frac{\pi t}{t_c} \right) \quad (2.11)$$

其中 α_m 代表最大相對位移。且當一個半徑 R 的球體接觸半無限域彈性體時，球體材料性質常數 k_1 與 α_m 如下：

$$\begin{cases} k_1 = \frac{3}{4\pi\rho_s R^3} \\ \alpha_m = \left[\frac{15\pi v_0^2}{16\sqrt{R}} (\delta_s + \delta_p) m_s \right]^{\frac{2}{5}} \\ \delta_p = \frac{1 - \nu_p^2}{E_p}, \quad \delta_s = \frac{1 - \nu_s^2}{E_s} \end{cases} \quad (2.12)$$

其中 m_s 表示鋼珠質量， ρ_s 表示鋼珠密度， R 表示鋼珠半徑 (m)， h 表示鋼珠掉落距離 (m)， ν_p 表示混凝土板柏松比， ν_s 表示鋼珠柏松比， E_p 表示混凝土板楊氏模數 (N/m²)， E_s 表示鋼珠楊氏模數 (N/m²)。

從式 (2.11) 可以知道接觸時間 t_c 與 α_m 有關係，再帶入式 (2.12) 中的 α_m 即可整理出下式：

$$t_c = \frac{\pi\alpha_m}{1.068v_0} = 5.97[\rho_s(\delta_s + \delta_p)]^{\frac{2}{5}} \frac{R}{h^{0.1}} \quad (2.13)$$

將上式放入鋼珠與混凝土版的材料性質 [41]，且 $h^{0.1}$ 對 t_c 的影響很小而忽略不計 [10]，最後得出 t_c 的近似值與 D 之間的關係式 (2.14)。

$$t_c = 0.00858 \frac{R}{h^{0.1}} \approx 0.0043D \quad (2.14)$$

其中 R 代表鋼珠半徑， D 代表鋼珠直徑。

也可再從式 (2.11) 與式 (2.12) 整理獲得 F_{\max} 以及 P_{\max} 。

$$F_{\max} = \frac{1.140v_0^2 m_s}{\alpha_m} \quad (2.15)$$

$$P_{\max} = \frac{3F_{\max}}{2\pi\alpha_m^2} = 0.2515 \left[\frac{v_0^2 m_s}{(\delta_s + \delta_p)^4 R^3} \right]^{\frac{1}{5}} \quad (2.16)$$

其中 g 表示重力加速度 (m/s^2)， v_0 表示鋼珠接觸表面時速度 (m/s)。





第三章 深度學習

深度學習的概念可以追溯到 Rosenblatt 提出的感知器 (perceptron) [38]。然而，單層感知器無法處理複雜模式或非線性可分離的資料集。為了克服這些限制，後來發展了多層感知器並且演化出各種深度學習模型。以下將介紹在後續研究使用的多層感知器 (multilayer perceptron, MLP)、全卷積神經網路 (fully convolutional networks, FCN)、殘差網路 (residual networks, ResNet) 和時間卷積網路 (temporal convolution network, TCN) 的原理與概念。

3.1 多層感知器

MLP 是一種前饋類神經網路 (feedforward neural network) 如圖 6.3 所示。主要由輸入層 (input layer)、隱藏層 (hidden layer) 與輸出層 (output layer) 組成。




圖 3.1 多層感知器示意圖 (兩層隱藏層)

正向傳播

正向傳播（forward propagation）是指神經網路中的數據從輸入層逐層傳遞到輸出層的過程。每個神經元接收前一層神經元的輸出，進行加權和偏差計算，再使用激勵函數獲得該層的輸出。

$$a_j^{(l)} = \sigma(z_j^{(l)}) = \sigma\left(\sum_k w_{ji}^{(l)} a_i^{(l-1)} + b_j^{(l)}\right) \quad (3.1)$$

其中 $w_{ji}^{(l)}$ 表示從 $l-1$ 層第 i 個神經元到 l 層第 j 個神經元的權重。 $b_j^{(l)}$ 表示 l 層第 j 個神經元的偏差。 $z_j^{(l)}$ 表示 l 層第 j 個神經元的線性組合， σ 為激勵函數， $z_j^{(l)}$ 經過激勵函數可以得到輸出 $a_j^{(l)}$ 。

假設 $l-1$ 層有 m 個神經元， l 層有 n 個神經元，因此從 $l-1$ 層到 l 層有 $m \times n$ 個權重， n 個偏差。也可以寫成矩陣形式如下式：

$$\mathbf{a}^{(l)} = \sigma(\mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}) \quad (3.2)$$

$$\text{其中 } \mathbf{a}^{(l-1)} = \begin{bmatrix} a_1^{(l-1)} \\ a_2^{(l-1)} \\ \vdots \\ a_m^{(l-1)} \end{bmatrix} \quad \mathbf{W}^{(l)} = \begin{bmatrix} w_{11} & w_{12} & \cdots & w_{1m} \\ w_{21} & w_{22} & \cdots & w_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n1} & w_{n2} & \cdots & w_{nm} \end{bmatrix} = \begin{bmatrix} w_1^{(l)} \\ w_2^{(l)} \\ \vdots \\ w_n^{(l)} \end{bmatrix} \quad \mathbf{b}^{(l)} = \begin{bmatrix} b_1^{(l)} \\ b_2^{(l)} \\ \vdots \\ b_n^{(l)} \end{bmatrix} \quad \mathbf{a}^{(l)} = \begin{bmatrix} a_1^{(l)} \\ a_2^{(l)} \\ \vdots \\ a_n^{(l)} \end{bmatrix}$$

在使用多層神經網路時，上層的輸出會成為下一層的輸入。如果沒有加入非線性函數，即便調整模型深度使其經過多層的線性組合，模型仍然只是表現出線性關係，而無法學習到數據中複雜的非線性關係。

$$\mathbf{y} = \mathbf{W}(\cdots(\mathbf{W}(\mathbf{W}\mathbf{x} + \mathbf{b}) + \mathbf{b}) + \cdots) + \mathbf{b} = \mathbf{W}'\mathbf{x} + \mathbf{b}' \quad (3.3)$$

因此每一層的輸出通常會通過一個非線性函數處理，這些函數被稱為激勵函

數。常用的激勵函數如圖 3.2 所示，包括 ReLU[33]、Tanh 和 Sigmoid。這些函數的非線性關係，能使深度學習模型能夠捕捉和學習更加複雜的數據分佈。



$$\begin{cases} \text{ReLU}(x) = \max(0, x) \\ \text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \\ \text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \end{cases} \quad (3.4)$$

(3.5)

(3.6)




圖 3.2 不同激勵函數輸出曲線

反向傳播

反向傳播 (backpropagation, BP) [39] 透過計算損失函式對權重與偏差的梯度來最佳化類神經網路參數。

首先定義損失函數 C 為均方誤差 (mean square error, MSE)。

$$C = \frac{1}{2n} \sum_x \|y(x) - a^L(x)\|^2 \quad (3.7)$$

反向傳播演算會先計算取得誤差 δ ，再計算 C 對權重 w 與偏差 b 的偏導數。首先要計算的是輸出層 L 的誤差 $\delta^{(L)}$ ：

$$\delta_j^{(L)} = \frac{\partial C}{\partial z_j^{(L)}} = \sum_k \frac{\partial C}{\partial a_k^{(L)}} \frac{\partial a_k^{(L)}}{\partial z_j^{(L)}} \quad (3.8)$$

且當 $k \neq j$ 時 $\frac{\partial a_k^{(L)}}{\partial z_j^{(L)}} = 0$ ，因此能夠化簡成下式：

$$\delta_j^{(L)} = \frac{\partial C}{\partial a_j^{(L)}} \frac{\partial a_j^{(L)}}{\partial z_j^{(L)}} = \frac{\partial C}{\partial a_j^{(L)}} \frac{\sigma(z_j^{(L)})}{\partial z_j^{(L)}} = \frac{\partial C}{\partial a_j^{(L)}} \sigma'(z_j^{(L)}) \quad (3.9)$$

對於隱藏層 l 的誤差 $\delta^{(l)}$ ，可以從輸出層到輸入層逐層計算誤差。

$$\delta_j^{(l)} = \frac{\partial C}{\partial z_j^{(l)}} = \sum_k \frac{\partial C}{\partial z_k^{(l+1)}} \frac{\partial z_k^{(l+1)}}{\partial z_j^{(l)}} = \sum_k \frac{\partial z_k^{(l+1)}}{\partial z_j^{(l)}} \delta_k^{(l+1)} \quad (3.10)$$

其中 $z_k^{(l+1)} = \sum_j w_{kj}^{(l+1)} \sigma(z_j^{(l)}) + b_k^{(l+1)}$ ，因此可以再整理成下式：

$$\delta_j^{(l)} = \sum_k w_{kj}^{(l+1)} \sigma'(z_j^{(l)}) \delta_k^{(l+1)} = \left(\sum_k w_{kj}^{(l+1)} \delta_k^{(l+1)} \right) \sigma'(z_j^{(l)}) \quad (3.11)$$

計算出每個神經元的誤差後，就可以計算權重 w 與偏差 b 的梯度。

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial z_j^{(l)}} a_k^{(l-1)} = a_k^{(l-1)} \delta_j^{(l)} \quad (3.12)$$

$$\frac{\partial C}{\partial b_j^{(l)}} = \frac{\partial C}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial b_j^{(l)}} = \frac{\partial C}{\partial z_j^{(l)}} \quad (3.13)$$


其中 $z_j^{(l)} = \sum_k w_{jk}^{(l)} a_k^{(l-1)} + b_j^{(l)}$

以一個 3 層類神經網路來說， C 對 $w_{13}^{(3)}$ 的偏導數如圖 3.3 且計算如下：

$$\frac{\partial C}{\partial w_{13}^{(3)}} = a_3^2 \delta_1^3 = a_{in} \delta_{out} \quad (3.14)$$

其中 a_{in} 是經過激勵函數後輸入給權重 w 的數值， δ_{out} 是輸出權重 w 神經元的誤差。

計算權重與偏差的梯度結合梯度下降法更新權重與偏差。除了梯度下






圖 3.3 具有三層結構的 MLP 對 $w_{13}^{(3)}$ 做偏導數

降法也可以使用隨機梯度下降法（stochastic gradient descent, SGD）、動量法（momentum）、RMSprop 與 Adam 等不同最佳化方法改善。

$$w^{(l)} \leftarrow w^{(l)} - \eta \frac{\partial C}{\partial w^{(l)}} \quad (3.15)$$

$$b^{(l)} \leftarrow w^{(l)} - \eta \frac{\partial C}{\partial b^{(l)}} \quad (3.16)$$

3.2 全卷積網路

FCN 是基於 CNN 發展而來的，因此先介紹 CNN 的基本概念。CNN 最早由 LeCun 等人所提出 [25]，LeNet 架構如圖 3.4 所示，主要應用於手寫數字辨識的 MNIST 資料集，在金融業的支票手寫數字識別中有廣泛的應用。當時提出的 LeNet 架構包含了卷積層、池化層、全連接層等重要架構，並成為後續 CNN 模型的基礎。




圖 3.4 LeNet-5 架構示意圖 [25]

卷積層

卷積層 (convolutional layer) 主要是利用多個卷積核 (filters) 從圖像中提取不同的特徵，輸出也稱為特徵圖 (feature map)。這些卷積核在網絡訓練過程中會調整其權重，以更精確的提取對最終分類有用的特徵。通過在外圍補零 (padding) 進行卷積運算，可以避免特徵圖的縮小。




圖 3.5 卷積層計算過程

池化層

池化層 (pooling layer) 通常在卷積層之後添加，其主要功能是對特徵圖進行降維處理，在減少計算複雜度的同時保留重要特徵，這有助於提高模型效率和泛化能力，並降低過擬合的風險。池化層不涉及權重學習，而是對其輸入進行特定操作，常見的池化方式包括最大池化 (max pooling)、平均池化 (average pooling) 與全局池化 (global pooling)。




圖 3.6 最大池化層計算過程

全連接層

全連接層（fully connected layer）將卷積層和池化層提取的特徵圖攤平成一維數據，每個神經元都與前一層的所有神經元相連接，綜合各特徵後進行最終的分類或回歸分析。這種結構使模型能夠處理複雜的非線性關係，從而提高分類的準確性。然而全連接層包含大量的參數，也導致模型變得非常龐大。

全卷積網路

FCN 由 Long 等人於 2015 年提出 [32]，其架構如圖 3.7 所示。是一種專門用於圖像語義分割的深度學習模型。

傳統的 CNN 架構通常在最後幾層使用全連接層進行圖像分類。全連接層會將前一層輸出的特徵圖展平為一個一維向量，從而忽略了圖像的空間結構資訊，因此僅適合進行全局分類。

FCN 則完全去除了全連接層，改用卷積層來保留圖像的空間資訊，從而達到像素的分類效果。由於 FCN 能夠輸出與輸入圖像相同大小的特徵圖，這一特性使得 FCN 在各種圖像分割任務中得到廣泛應用。




圖 3.7 FCN 架構示意圖 [32]

3.3 殘差網路

從 2012 年 AlexNet 模型 [24] 在 ImageNet Large Scale Visual Recognition Challenge (ILSVRC) 中獲得冠軍，並顯著優於傳統方法的深度學習模型。後續 ILSVRC 比賽中出現的 VGG[42]、Inception[44] 等模型在更深層網路上展現了更優異的表現。

理論上在一個淺層網路堆疊許多能夠恆等映射層變成深層網路，深層網路應該至少與淺層網路有一樣的表現。然而堆疊更深層的網路卻沒有表現更好如圖 3.8，除了梯度消失問題導致模型無法順利收斂，還看到訓練誤差與測試誤差都變高了，這表示更深的網路出現了退化 (degradation)。




圖 3.8 在 CIFAR-10 資料集上更深的網路具有更高的訓練誤差以及測試誤差 [15]

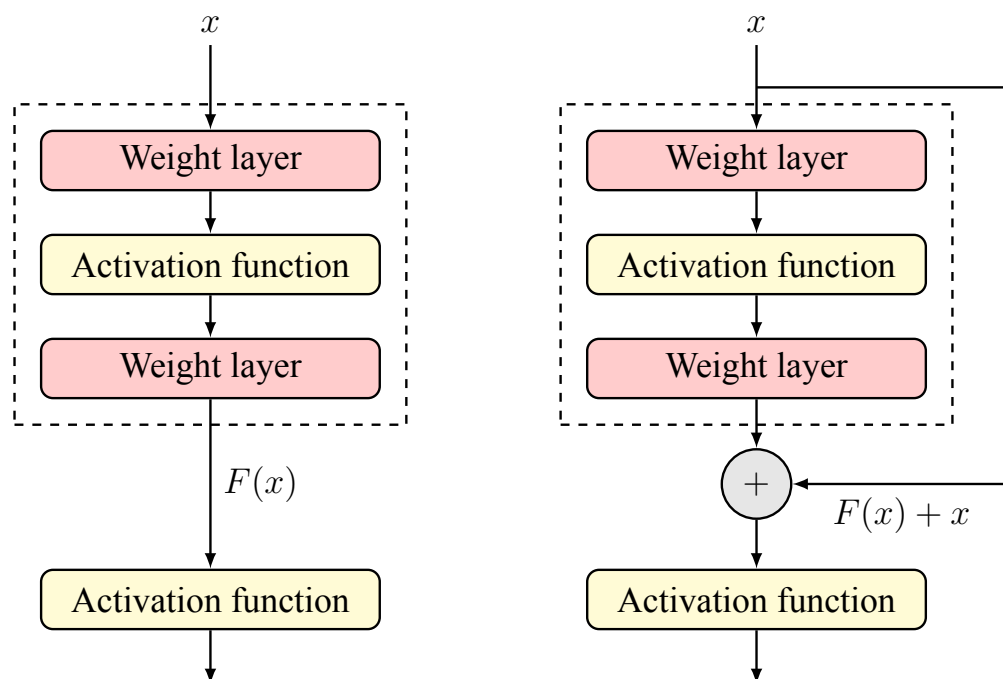


圖 3.9 傳統結構與殘差區塊差別



He 等人提出的 ResNet[15] 如圖 3.9 所示，透過捷徑連接（shortcut connection）解決了梯度消失問題，確保梯度能夠順利反向傳播。對一個多層的 ResNet 模型，其輸出可以表示如下：

$$x_{l+1} = F(x_l) + x_l \quad (3.17)$$

在反向傳播中，損失函數 L 對第 l 層的輸入 x_l 的梯度可以透過連鎖律表示。

$$\begin{aligned} \frac{\partial L}{\partial x_l} &= \frac{\partial L}{\partial x_{l+1}} \frac{\partial x_{l+1}}{\partial x_l} = \frac{\partial L}{\partial x_{l+1}} \left(1 + \frac{\partial F(x_l)}{\partial x_l} \right) \\ &= \frac{\partial L}{\partial x_{l+1}} + \frac{\partial L}{\partial x_{l+1}} \frac{\partial F(x_l)}{\partial x_l} \end{aligned} \quad (3.18)$$

由上式可以看到即使 $\frac{\partial F(x_l)}{\partial x_l}$ 非常小，梯度仍然可以透過 $\frac{\partial L}{\partial x_{l+1}}$ 反向傳播回前層，並一定程度上緩解了梯度消失問題。

殘差區塊（residual block）的設計使得更深層的網絡能夠高效且穩定地訓練，不僅大幅改善模型表現，也推動了許多深度學習模型採用殘差連接提升性能。

3.4 時間卷積網絡

在分析處理序列資料時，遞迴神經網路（recurrent neural network, RNN）是一種常用的模型架構。但由於梯度爆炸與梯度消失問題 [5, 34]，通常會使用更複雜的模型，如 LSTM（long short-term memory）[17] 與 GRU（gated recurrent unit）[9]。然而，由於 RNN 模型在每個時間步長都需要前一個時間步長的輸出，因此難以平行化運算，導致訓練效率低下。

Bai 等人提出的 TCN[4] 參考了其他序列特性 CNN 架構 [12, 22, 47]，解決 RNN 中常見的梯度爆炸與消失問題並能夠平行化運算。TCN 主要有兩個特點，第一個是因果卷積（causal convolutions），確保當前時間步長資料不會接受到未來的

資訊。第二個是擴張卷積 (dilated convolutions)，使模型在接受任何長度時間序列資料時有足夠的感受域 (receptive field)。TCN 模型結構如圖 3.10 所示，以下將對 TCN 的特點進行介紹。



因果卷積

TCN 模型為了使輸出與輸入資料長度相同，使用一維 FCN 架構 [32]，並且透過補零使每個隱藏層長度都與輸入層長度相同。另外 TCN 使用因果卷積確保當前輸出只與過去輸入有關，代表在時點 t 的產出值只能由時點 t 與 t 之前的輸入有關。

因此簡單來說，TCN 就是在一維 FCN 架構中加入因果卷積，這也與早年 Waibel 等人提出的結構相同 [48]。然而，為了有效擷取足夠的歷史資訊，需要非常深的網路或非常大的卷積核，這些方法在當時是難以實現的。現代的卷積架構使得這些方法成為可能，以下會進一步的說明。

擴張卷積

由於單純使用因果卷積只能捕捉與模型深度相同的歷史資訊，這使得需要長時間歷史資訊的時間序列任務非常具有挑戰性。為了解決這個問題，TCN 與 Van Den Oord 等人 [47] 同樣使用擴張捲積，使感受域以指數方式擴大。在使用擴張卷積時，常用的做法是讓擴張因子 d 隨著網路深度指數增加（即在第 i 層時， $d = O(2^i)$ ），這樣可以保證有效歷史範圍內的每個輸入值都會被卷積核擷取到。

殘差連接

由於 TCN 的感受域取決於網路深度、卷積核大小與擴張因子，更深層的 TCN 模型穩定性變得非常重要，因此 TCN 模型中加入了殘差連接 [15]。在殘差

區塊中，使用了兩層擴張因果卷積和激勵函數 ReLU[33]，並採用了權重正規化 (Weight Normalization, WN) [40] 來進行正規化。此外，還在擴張因果卷積後加入了 dropout[43]，在訓練時隨機將某些神經元的輸出歸零，以提高模型的泛化能力。

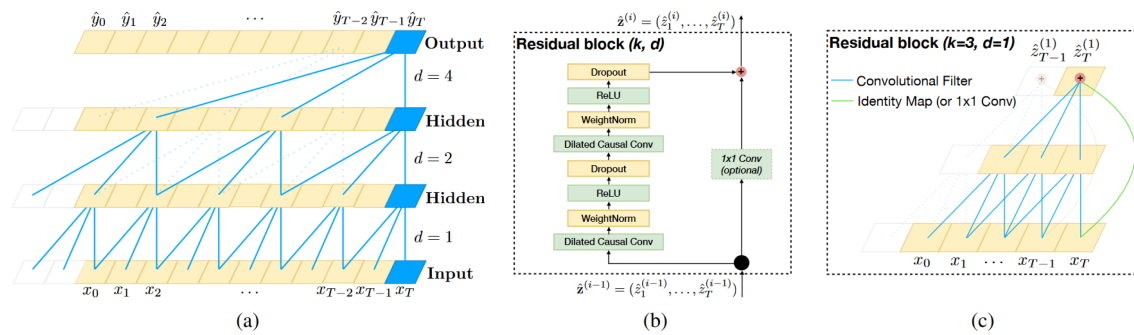


圖 3.10 TCN 模型結構 (a) 擴張因果卷積，其中擴張因子 $d=1,2,4$ ，卷積核大小 $k=3$ 。(b) 殘差區塊架構。(c)TCN 殘差連接實際範例。[4]



第四章 模型架構

經過上一章的介紹，已經對 MLP、FCN、ResNet 與 TCN 有了基本了解。以下將詳細說明本研究使用的模型架構。其中，MLP、FCN 與 ResNet 模型的參數是基於 Wang 等人 [49] 在 UCR 時間序列資料集 [8] 上的測試結果所設計，而 TCN 模型的參數則使用 Bai 等人 [4] 在一維 MNIST 資料集上的測試結果。這些模型參數是為 TSC 任務設計的，而本研究要利用敲擊回音時訊號來預測裂縫或底部深度是屬於 TSER 任務。但根據 Tan 等人的研究 [45]，應用於 TSC 任務的模型在經過適當調整後在 TSER 任務上也能表現優異，因此本研究將這些模型應用於敲擊回音訊號上。

4.1 MLP




圖 4.1 MLP 架構圖

本研究使用的 MLP 模型如圖 4.1 所示，由三層全連接層（fully connected, FC）組成。每個 FC 層包含 500 個神經元，並在每一層輸入時使用 dropout，能在訓練



時隨機將某些神經元的輸出歸零，以提高模型泛化能力，並使用激勵函數 ReLU 防止梯度飽和。透過 ReLU 與 dropout 有助於建構較深的網路，其中 dropout 比率依序為 0.1, 0.2, 0.2, 0.3。

4.2 FCN




圖 4.2 FCN 架構圖

本研究使用的 FCN 模型如圖 4.2 所示。不同於語意分割的 FCN，此模型不會對將每個像素進行分類，而是僅使用其卷積層提取特徵。在每個卷積層後面會接著批次正規化 (batch normalization, BN) [18] 加快收斂速度與提升泛化能力，並使用激勵函數 ReLU 防止梯度飽和，同時不使用任何池化層。最終模型由 3 個卷積層構成，其中卷積核大小 $k = 7, 5, 3$ ，卷積核數量 $f = 128, 256, 128$ 。經過卷積後的特徵經過全域平均池層 (global average pooling, GAP) [28] 而不是全連接層，可以很好的減少權重數量。

4.3 ResNet




圖 4.3 ResNet 架構圖

本研究使用的 ResNet 模型主要透過殘差連接的設計 [15]，有效堆疊模型的深度與穩定性。ResNet 模型主要將 FCN 模型使用的 3 個卷積層構成一個殘差區塊，最終，ResNet 模型共使用了 3 個殘差區塊如圖 4.3 所示，其中每個殘差區塊中卷積核 $k = 64, 128, 128$ ，並在每個殘差區塊中使用殘差連接。同樣的，卷積後的特徵通過 GAP 層輸出，有效的減少權重數量。

4.4 TCN




圖 4.4 TCN 架構圖

本研究使用的 TCN 模型如圖 3.10 所示，為了構建深層且穩定的模型，也同樣使用殘差連接 [4]。在每個殘差區塊中，包含 2 個擴張因果卷積，在每個卷積層後面會接著權重正規化（Weight Normalization, WN）[40] 與激勵函數 ReLU 防止梯度飽和。最終，TCN 模型共使用 8 個殘差區塊，其中卷積核大小 k 均為 7，卷積核數量 f 均為 25，擴張因子分別是 $d = 1, 2, 4, 8, 16, 32, 64, 128$ 。同樣的，卷積後的特徵通過 GAP 層輸出，有效的減少權重數量。

4.5 共同設定

權重初始化

MLP、FCN 與 ResNet 使用 He normal initialization 進行初始化 [14]，TCN 模型使用與原文相同的權重初始化方法 [4]。

最佳化器

本研究的損失函數 L 使用均方誤差 (mean square error, MSE)，透過計算誤差對模型權重最佳化更新。最佳化方法與原文相同 [4, 49]，MLP 使用 Adadelta 最佳化 [52]，其中學習率 $\eta = 0.1$ ， $\rho = 0.95$ 以及 $\epsilon = 1e-8$ 。FCN、ResNet 與 TCN 則是使用 Adam[23] 最佳化，其中學習率 $\eta = 0.001$ ， $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ 以及 $\epsilon = 1e-8$ 。

$$L(x, y) = \sum_{i=1}^N \frac{(x_i - y_i)^2}{N} \quad (4.1)$$

其他設定

批次大小 (batch size) 設定為 32，訓練週期 (epoch) 設定為 300。

環境設定

本研究使用了 Intel Core i9-10900K 處理器和 NVIDIA TITAN RTX 顯示卡，並搭配 32GB 的 DRAM 在 Windows 10 系統上運行。深度學習框架選擇了 PyTorch 2.2.1，使用的程式語言為 Python 3.9.9。所有模型的訓練與測試均在此配置下進行。



第五章 資料集

5.1 數值模擬訊號

在進行深度學習訓練時需要大量的資料，但準備大量混凝土試體進行敲擊實驗並不是一個有效率的方法。因此，本研究使用有限元素法模擬不同試體與裂縫的敲擊回音訊號。以下介紹本研究的數值模擬流程與參數設定。

5.1.1 數值模擬流程

本研究使用了 ANSYS 與 LS-DYNA 兩種有限元素分析軟體建立數值模型，模擬混凝土在不同條件下的敲擊訊號。模擬分析過程包括前處理（pre-processing）、求解（solving）以及後處理（post-processing）三大步驟。

在前處理階段可以細分成建立幾何模型、網格分割、定義元素型態與材料性質以及設定載重與反射邊界條件。本研究分別使用了 LS-DYNA 的前處理器 FEMB（Finite Element Model Builder）和 ANSYS Mechanical APDL（ANSYS Parametric Design Language）的圖形使用者介面（GUI）。



幾何模型

在建立幾何模型的階段時，會根據需求選擇 FEMB 或 APDL 進行後續操作。FEMB 是一種較為傳統的繪圖軟體，透過逐步建立端點、線段和平面來構建模型。這種方法的優點是進行網格分割後得到的節點編號與元素編號有規則與連續性，有助於降低後續求解過程的計算時間，但對於形狀複雜試體較難建立模型。相比之下，APDL 提供了現代化的圖形介面能夠直接建立 3D 模型，但其網格分割時可能會導致節點編號與元素編號較無規則性，增加求解過程的計算負擔。本研究選擇使用 FEMB 建立水平裂縫試體，而傾斜裂縫則是透過 APDL 建構模型。

網格分割

在有限元素分析中，網格分割是最重要的步驟之一。網格尺寸越小能夠提供更精準的結果，但也會大幅增加計算的時間；反之，較大的網格可以減少計算量，但結果可能較不精準。本研究的數值模擬屬於暫態分析，通常對於網格的劃分之長寬比不可超過三分之一，為此使用網格長寬高都是均為 1cm 的六面體網格。

元素型態與材料性質

選擇元素型態時，需要考慮結構之幾何形狀與分析目的。元素型態包含適合桿件或桁架的一維元素、薄殼與平板的二維元素以及三維元素。由於本研究使用的混凝土是三維結構，因此採用三維元素進行分析。

在選擇混凝土材料性質時，考慮到鋼珠敲擊所產生的低頻應力波波長遠大於混凝土內部的孔洞與骨材，因此可以將混凝土直接視為均質且等向的線彈性材料。本研究所使用的材料參數如表 5.1 所示。




表 5.1 材料參數

材料	密度 (kg/m ³)	楊氏模數 (GPa)	柏松比
混凝土-1	2300	33.1	0.2
混凝土-2	1800	25	0.2
混凝土-3	2500	50	0.2

載重與邊界條件

本研究設定載重時從負載壓力與時間的變化來模擬敲擊源。敲擊時作用力如前面所述，近似一半週期正弦波，並根據式 (2.16) 獲得敲擊產生的最大壓力，而式 (2.14) 可以求得不同鋼珠直徑的接觸時間。依照計算鋼珠直徑與接觸時間如表 5.2 所示，並可以畫出圖 5.1 壓力與接觸時間之曲線。

表 5.2 鋼珠直徑所對應接觸時間

鋼珠直徑 (mm)	接觸時間 (μs)
4	17
6	26
10	43





圖 5.1 鋼珠直徑所對應作用力時間圖

本研究在試體的反射條件包含了三種情況：底部與側面都不反射的半無限域 (half-space, HS)、底部反射側邊不反射的無限平板 (infinite plate, IP) 以及底部與側邊都反射的有限平板 (finite plate, FP)。



求解

在求解設定中，LS-DYNA 會根據網格大小自動設定最小取樣時間間隔為 $1.57\mu\text{s}$ ，且設定總取樣時間為 3ms 。接收器節點擺放位置設定在距敲擊點 4cm 的位置，上下左右各擺放兩個接收器，因此每個敲擊源總共有 8 個接收器。完成設定後，使用 ANSYS/LS-DYNA 求解器進行求解。

後處理

在最後的後處理階段，本研究使用 LS-PrePost 顯示求解後的模擬結果，並著重分析混凝土中的縱向位訊號。

5.1.2 數值模擬試體

本研究使用的數值模型依照試體可分為三種，其詳細資訊如表 5.3 所示。第一種與第二種分別是厚度 30cm 與 20cm 且內部有不同裂縫深度試體，第三種則是不同厚度無裂縫試體。

表 5.3 模擬試體資訊

編號	試體尺寸 (cm)	裂縫尺寸 (cm)	裂縫深度 D(cm)
N1	$80 \times 80 \times 30$	$32 \times 32 \times 1$	4, 6 ~ 26
N2	$80 \times 80 \times 20$	$32 \times 32 \times 1$	6 ~ 17
N3	$80 \times 80 \times 6$ $80 \times 80 \times 26$, $80 \times 80 \times 30$	—	—

5.2 實驗訊號

本研究希望透過實驗訊號驗證訓練的模型準確性與實務可行性。以下介紹本研究用到的實驗流程與實驗設備。



5.2.1 實驗設備

示波器

本研究實驗訊號分別由 Teledyne LeCroy Wavesurfer 24Xs 與 WaveSurfer 4024HD 示波器將接收到的類比訊號轉為數位訊號儲存。Wavesurfer 24Xs 設定的取樣時距為 $1\mu\text{s}$ 取樣時間為 5ms，共 5000 個取樣點。WaveSurfer 4024HD 設定的取樣時距為 $1.6\mu\text{s}$ 取樣時間為 5ms，共 3125 個取樣點。

位移感測器

感測器是由國立臺灣大學應用力學研究所超聲波實驗室利用壓電材料製作而成，並以 BNC 傳輸線連接示波器。

鋼珠

本研究使用鋼珠直徑分別為 6mm 與 10mm，本研究將不鏽鋼鋼珠焊接在鋼棒上方便敲擊。

5.2.2 實驗試體

本研究使用的實驗試體資訊如表 5.4 所示，各試體側視圖與上視圖見圖 5.5 至圖 5.10。分別是試體厚度為 20cm 內含深度 6cm 和 10cm 的水平裂縫，以及深度 12-8cm 和 14-6cm 的傾斜裂縫。此外，還有試體厚度為 50cm 且深度為 25cm 的深層水平裂縫。

表 5.4 實驗試體資訊

編號	試體尺寸 (cm)	裂縫尺寸 (cm)	裂縫深度 D(cm)
E1	80×80×20	32×32×1	6
E2			10
E3			12
E4			14-6
E5		32×80×1	12-8
E6	120×80×50	24×80×1	25

當試體擺放時間過久時，混凝土可能會出現劣化問題，因此在進行實驗前量測試體的縱波波速是必要的。本研究根據 ASTM C1383 標準測量縱波波速，將兩個位移感測器 R1 和 R2 相距約 300mm 擺放，並在距離 R1 位移感測器約 150mm 的位置敲擊鋼珠，如圖 5.2 所示。由於已知兩個感測器之間的距離，從圖 5.3 可以判讀各自感測器的縱波與表面波的首達波時間，因此可以計算出縱波波速與表面波波速。再根據式 (2.3) 推算橫波波速。知道縱波、橫波與表面波的波速後，就可以使用式 (2.4) 計算出試體的柏松比。




圖 5.2 量測波速示意圖

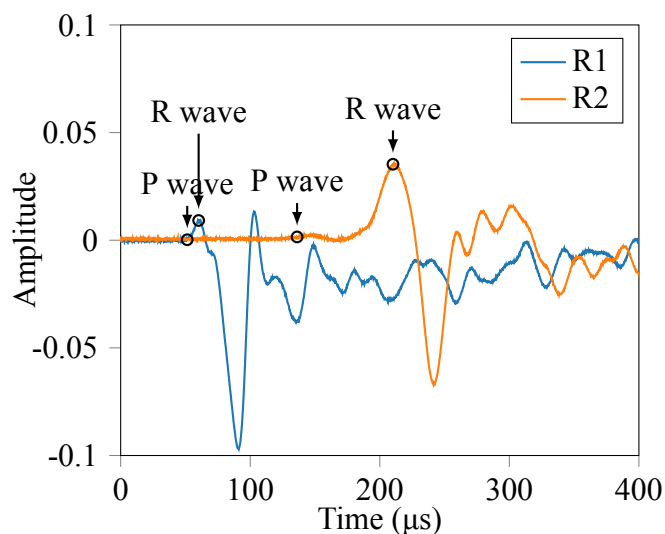


圖 5.3 量測波速之訊號

表 5.5 實驗試體物理性質

編號	縱波波速(m/s)	橫波波速(m/s)	表面波速(m/s)	柏松比
E1	3900	2130	2328	0.21
E2	3717	2053	2249	0.20
E3	3890	2150	2357	0.20
E4	3900	2180	2393	0.19
E5	3542	2006	2210	0.18
E6	4039	2267	2494	0.19

實驗試體的量測方式根據平行於 x 軸和 y 軸的測線進行敲擊。測線之間的間距為 4cm，與邊界的最近距離為 2cm。換句話說，平行於 y 軸的第一條測線位於 $x = 2\text{cm}$ ，第二條測線位於 $x = 6\text{cm}$ ，第三條測線位於 $x = 10\text{cm}$ ，依此類推。 x 和 y 方向測線的交點即為敲擊位置。進行試驗時，敲擊點設在方格的右上方，而接收點設在左下方，如同圖 5.4 的示意圖方式敲擊。




圖 5.4 實驗敲擊位置示意圖




圖 5.5 試體厚度 20cm 裂縫深度 6cm 實驗試體




圖 5.6 試體厚度 20cm 裂縫深度 10cm 實驗試體




圖 5.7 試體厚度 20cm 裂縫深度 12cm 實驗試體




圖 5.8 試體厚度 20cm 裂縫深度 12-8cm 實驗試體




圖 5.9 試體厚度 20cm 裂縫深度 14-6cm 實驗試體




圖 5.10 試體厚度 50cm 裂縫深度 25cm 實驗試體



5.3 訊號輸入長度選取

在將敲擊回音訊輸入深度學習模型前，需要決定合適的輸入長度。由於 26cm 裂縫要在時間長度 $T \approx \frac{0.26 \cdot 2}{4000} = 130\mu\text{s}$ （序列長度 $N = 81$ ）之後才會接受反射訊號，因此接受訊號至少要大於此時間長度才能判斷其反射深度。然而在本研究測試的最小試體厚度 20cm 來說在 $T \approx \frac{0.20 \cdot 2}{4000} = 100\mu\text{s}$ （序列長度 $N = 63$ ）會有來自底部反射的干擾影響。

如果挑選序列長度 $N = 100$ （時間長度 $T = 160\mu\text{s}$ ），較深層裂縫的反射訊號剛到達，資訊量過少。然而，若選擇過長的輸入長度，則會造成底部與側邊的反射訊號影響過大判讀困難。因此經過測試本研究選擇序列長度 $N = 200$ （時間長度 $T = 320\mu\text{s}$ ），能夠在深層裂縫反射能來回多次情況下，又不會受到太多底部或側邊反射的影響。

5.4 訊號前處理

5.4.1 基本處理

在進行數值模擬與實驗訊號的分析之前，需要對示波器接收的實驗訊號進行前處理。以下介紹數值模擬與實驗訊號需要進行的基本處理步驟，其步驟如圖 5.11 所示




圖 5.11 對實驗訊號進行基本處理過程 (a) 對實驗訊號進行濾波。(b) 判讀訊號時間原點。(c) 對訊號重新取樣與正規化

濾波

在實驗過程中，訊號不可避免地會受到周圍環境或設備本身的雜訊影響，因此使用濾波濾除雜訊是有幫助的。本研究使用了兩種低通濾波方式，平均濾波器（averaging filter）與巴特沃斯濾波器（butterworth filter）。

平均濾波器的原理是對訊號周圍取平均值使訊號變得更加平滑，有效地減少高頻雜訊。

$$y[n] = \frac{1}{N} \sum_{k=0}^{N-1} x[n+k] \quad (5.1)$$

其中 $y[n]$ 是濾波後的訊號， $x[n]$ 是原始訊號， N 是窗口大小。

巴特沃斯濾波器是一種設計為在通帶內具有平坦頻率響應的濾波器，並且在截止頻率處迅速衰減。

$$H(s) = \frac{1}{\sqrt{1 + \left(\frac{\omega}{\omega_c}\right)^{2n}}} \quad (5.2)$$

其中 n 是濾波器的階數， ω_c 是截止頻率。

時間原點

由於實驗訊號不像模擬訊號有準確的時間原點，示波器擷取到的訊號並不是

從敲擊源接觸表面的瞬間開始，因此需要自行擷取時間原點。本研究透過計算觸發前訊號的雜訊最大值、最小值與標準差判斷，當某點超過最大值或最小值三個標準差時，視為縱波的首達波。首達波時間再扣除敲擊源與感測器之間傳遞的時間後便是實驗訊號時間原點。

重新取樣與正規化

由於模擬訊號與實驗訊號的取樣率不同，本研究透過線性插值將訊號取樣時距固定為 $1.6\mu\text{s}$ 。

在模擬與實驗中，會使用不同大小的鋼珠進行敲擊，且實驗時每次敲擊的力度也有所不同，這會導致敲擊反射訊號的強度不同。為了確保訊號的一致性，需要對這些敲擊後的訊號進行正規化處理。本研究將每次敲擊後表面波的最低點調整為 -1，以標準化敲擊訊號的幅度。

5.4.2 資料增強

資料增強 (data augmentation) 通過改變特徵的位置，同時保留特徵之間的相對關係，以增加訓練資料的多樣性，從而改善深度學習模型的性能和泛化能力。本研究參考了其他研究在時間序列使用的資料增強方法 [21, 31, 46, 50]，希望夠進一步提升模型的泛用能力。

雜訊 (Noising)

在時間序列資料增強方法中，簡單而有效的方法是在時間序列中加入雜訊，也可以模擬在實驗中接受到影響雜訊的情況。

$$\mathbf{x}' = x_1 + \epsilon_1, x_2 + \epsilon_2, \dots, x_T + \epsilon_T \quad (5.3)$$

其中 \mathbf{x}' 表示加入雜訊後的訊號， x_T 表示時間步長 T 時的原始訊號， ϵ 表示在時間步長 i 加入的雜訊並且是由高斯分布，其平均值為 0 標準差 σ 或表示成 $\epsilon \sim N(0, \sigma^2)$ ，如圖 5.12 為高斯分布雜訊，圖 5.13 對原始訊號加入雜訊，是一個能夠有效提高神經網路泛化能力的方法 [2, 6]。




圖 5.12 雜訊大小分布




圖 5.13 原始模擬訊號加入雜訊

平移 (Sliding)

由於實驗訊號需要在前處理階段找出時間原點。將實驗訊號與模擬訊號比較會發現，兩者在表面波最低點之間的差距平均約為 $10 \sim 20\mu\text{s}$ 。希望透過平移訊號改變其時間原點。

縮放 (Scaling)

縮放透過縮放係數 α 改變整體時間序列訊號的幅度或強度，又可以成寫以下：

$$\mathbf{x}' = \alpha x_1, \alpha x_2, \dots, \alpha x_T \quad (5.4)$$

其中 \mathbf{x}' 表示加入雜訊後的訊號， x_T 表示時間步長 T 時的原始訊號， α 表示縮放係數，由高斯分布決定，其平均值為 1 標準差 σ 或表示成 $\alpha \sim N(1, \sigma^2)$ ，如圖 5.14 選擇整體訊號縮放係數，圖 5.15 對原始訊號進行整體縮放。




圖 5.14 縮放係數大小




圖 5.15 原始模擬訊號進行縮放

振幅扭曲 (Magnitude warping)

振幅扭曲是一種時間序列資料增強方式，透過平滑曲線扭曲訊號振幅 [46]。

$$\mathbf{x}' = \alpha_1 x_1, \alpha_2 x_2, \dots, \alpha_T x_T \quad (5.5)$$

其中 $\alpha_1, \alpha_2, \dots, \alpha_T$ 是透過三次樣條插值 (cubic spline interpolation) 序列 $u = u_1, u_2, \dots, u_i$ 所生成。 u_i 是由高斯分佈，其平均值為 1 標準差 σ 也可表示成 $u \sim N(1, \sigma^2)$ 。序列 u 即是圖 5.16 中的紅點，這些紅點是由高斯分布生成的，對這些紅點進行三次樣條插值後得到縮放係數，圖 5.17 為原始訊號經過縮放係數扭曲情況。幅度扭曲透過在時間序列中隨機增加或減少小波動，達成資料增強目的。然而振幅扭曲的缺點是需要假設變換後的訊號仍然符合現實及其物理意義。




圖 5.16 振幅扭曲曲線




圖 5.17 原始模擬訊號進行振幅扭曲



時間扭曲 (Time warping)

時間扭曲透過平滑的扭曲路徑，在時間維度上擾動改變訊號 [46]。

$$\mathbf{x}' = x_{\tau(1)}, x_{\tau(2)}, \dots, x_{\tau(T)} \quad (5.6)$$

其中 $\tau(\cdot)$ 是根據平滑曲線把時間步長改變的函數。平滑曲線也是由三次樣條插值序列 $u = u_1, u_2, \dots, u_i$ 定義每個時間步長距離，其平均值為 1 標準差 σ 或表示成 $\alpha \sim N(1, \sigma^2)$ 。透過此方法能在使時間步長平滑拉伸或縮放改變時間序列資料。




圖 5.18 時間步長扭曲曲線




圖 5.19 原始模擬訊號進行時間扭曲

5.5 訓練集及測試集

本研究使用半無限域數值模擬試體作為訓練集如表 5.6 所示。對每種裂縫深度和每種鋼珠直徑各收集 200 筆敲擊訊號，並在後續訓練時採用了兩種方式：

1. 根據裂縫深度選擇鋼珠直徑進行敲擊。在 11 個裂縫深度下共 $11 \times 200 = 2200$ 筆敲擊訊號。
2. 在所有裂縫深度使用 4, 6, 10mm 鋼珠直徑進行敲擊，在 11 個裂縫深度下使用 3 種不同鋼珠直徑，共 $11 \times 3 \times 200 = 6600$ 筆敲擊訊號。

表 5.6 所有訓練集資訊

訓練集	反射條件	試體厚度 H(cm)	裂縫深度 D(cm)	鋼珠直徑 (mm)	訊號數量
1	半無限域	30	6, 8, 10, 12, 14, 16	6	2200
			18, 20, 22, 24, 26	10	
2			6, 8, 10, 12, 14, 16	4, 6, 10	6600
			18, 20, 22, 24, 26		

模擬訊號測試集包括無限平板和有限平板兩種情況，並依照裂縫深度選擇敲擊鋼珠直徑如表 5.7 所示。無限平版主要分成三種不同情形，同樣在每種裂縫深度各收集 200 筆敲擊訊號：

1. 試體厚度為 30cm，內部有內插裂縫深度 6 至 26cm，以及外插裂縫深度 4cm，共 4400 筆敲擊訊號。
2. 試體厚度為 20cm，內部有內插裂縫深度 6 至 16cm，共 2400 筆敲擊訊號。
3. 內插試體厚度 6 至 26cm，外插試體厚度 30cm 且內部無裂縫，共 4400 筆敲擊訊號。

有限平版使用的試體厚度都是 20cm，並在內部有水平裂縫深度 6cm 與 10cm 以及傾斜裂縫深度 12-8cm 與 14-6cm 四種情況。本研究對試體進行完整敲擊，測點之間間隔 4cm，每個試體有 $19 \times 19 = 361$ 筆敲擊訊號。

表 5.7 所有測試集模擬訊號資訊

測試集	反射條件	試體厚度 H(cm)	裂縫深度 D(cm)	鋼珠直徑 (mm)	訊號數量
1	無限平板	30	4, 6 ~ 16	6	4400
			18 ~ 26	10	
2		20	6 ~ 16	6	2400
3		6 ~ 16 18 ~ 26, 30	—	6 10	4400
4	有限平板	20	6	6	361
			10		361
			12-8		361
			14-6		361

最後是實驗試體測試集如表 5.8 所示，本研究對試體厚度 20cm 內部包含水平裂縫深度 6cm 與 10cm 以及傾斜裂縫深度 12-8cm 與 14-6cm 的四種試體進行整體敲擊。各個測點之間間隔 4cm，每個試體有 $19 \times 19 = 361$ 筆敲擊訊號。此外，對於厚度為 20cm 且內部水平裂縫深度為 12cm，以及厚度為 50cm 且內部水平裂縫深度為 25cm 的試體，因為先前敲擊訊號沒有對試體整體進行量測，僅對裂縫中心附近敲擊，這兩種試體則各收集 50 筆敲擊訊號。

表 5.8 所有測試集實驗訊號資訊

測試集	反射條件	試體厚度 H(cm)	裂縫深度 D(cm)	鋼珠直徑 (mm)	訊號數量
5	實驗試體	20	6	6	361
			10		361
			12		50
			12-8		361
			14-6		361
		50	25	10	50



第六章 結果與討論

6.1 模擬訊號結果

首先本研究對 MLP、FCN、ResNet 與 TCN 四種模型選擇較適合的網路。在進一步調整卷積層深度、卷積核大小與數量。並討論雜訊、平移訊號對模型的影響。表 6.1 與表 6.2 是討論時所使用的訓練集與測試集。本研究在評估模型時使用平均絕對誤差 (mean absolute error, MAE)，測試集以此結果對模型進行討論與調整。

表 6.1 依照裂縫深度選擇鋼珠直徑之訓練集資訊

訓練集	反射條件	試體厚度 H(cm)	裂縫深度 D(cm)	鋼珠直徑 (mm)	訊號數量
1	半無限域	30	6, 8, 10, 12, 14, 16	6	2200
			18, 20, 22, 24, 26	10	

表 6.2 使用與訓練集相同深度之測試集資訊

測試集	反射條件	試體厚度 H(cm)	裂縫深度 D(cm)	鋼珠直徑 (mm)	訊號數量
1	無限平板	30	6, 8, 10, 12, 14, 16	6	2200
			18, 20, 22, 24, 26	10	
2		20	6, 8, 10, 12, 14, 16	6	1200
3		6, 8, 10, 12, 14, 16	—	6	2200
		18, 20, 22, 24, 26		10	



$$\text{MAE} = \frac{\sum_{i=1}^N |x_i - y_i|}{N} \quad (6.1)$$

6.1.1 模型選擇

從圖 6.1 的訓練過程可以發現 MLP 與 FCN 在最後收斂值明顯高於 ResNet 與 TCN。由於 MLP 與 FCN 模型的架構較為簡單，因此對敲擊回音訊號提取的特徵較不佳。相比之下，ResNet 與 TCN 透過殘差連接，使網路能夠以更深層且複雜的結構進行訓練，從而更好的提取敲擊回音訊號特徵。這也證實了殘差連接可以幫助訓練深層網路。

從表 6.3 得知，在半無限域的訓練資料中，ResNet 與 TCN 的表現明顯優於 MLP 與 FCN。而在無限平板的測試數據中，ResNet 與 TCN 在面對不同底部反射干擾時，TCN 的表現明顯優於 ResNet，這表明 TCN 的因果與擴張卷積結構在處理複雜反射條件下具有優勢，也顯示其應用於實際訊號中可能具有更好的適應性與穩定性，同時更進一步討論 TCN 的各種參數。




圖 6.1 MLP、FCN、ResNet 與 TCN 訓練過程

表 6.3 MLP、FCN、ResNet 與 TCN 訓練與測試結果

Training Set	MAE (cm)			
	MLP	FCN	ResNet	TCN
HS	0.416	0.185	0.035	0.031

Testing Set	MAE (cm)			
	MLP	FCN	ResNet	TCN
IP H = 30	1.171	3.005	0.855	0.107
IP H = 20	2.042	5.089	1.253	0.399
IP No Crack	12.03	7.344	1.490	0.404

6.1.2 TCN 模型參數

透過前面的比較已經知道 TCN 架構能夠有效提取敲擊回音訊號特徵。但由於此模型是 Bai 等人根據一維 MNIST 資料集測試所設計 [4]，本研究透過調整卷積層深度、卷積核大小以及卷積核數量找到更適合應用於敲擊回音資料集上。

卷積層深度

本研究透過改變殘差區塊的數量來調整卷積層的深度以期望模型有更低的誤差深度。結果如表 6.4 所示，整體模型表現隨著深度增加而有所改善，如同前一小節提及，較淺的模型無法有效提取敲擊回音訊號特徵。但隨著深度的提升，特別是在使用 7 個殘差區塊時，測試集誤差卻明顯增加。這可能是由於模型過於複雜且在訓練集上過度擬合，導致在測試集上表現不佳。

綜合考慮不同深度的模型表現，本研究後續使用 5 個殘差區塊的模型，因為除了在測試集中有最小誤差外，較少的卷積層會降低模型複雜度並能節省運算資源，可以使模型在實際應用中更有優勢。



表 6.4 卷積層深度

Kernel Size: 7, Filter: 25	
Residual Block	MAE (cm)
3	4.736
4	1.240
5	0.228
6	0.338
7	1.015
8	0.286

卷積核大小

接著調整卷積核大小，如表 6.5 所示，可以看到卷積核大小對模型的表現有顯著的影響。當使用過小的卷積核時，模型的表現較差，這可能是因為卷積核太小無法捕捉足夠的時間序列特徵。而當卷積核增加到一定大小後，模型的表現會顯著改善，因為較大的卷積核可以覆蓋更廣的時間範圍，捕捉到更多有用的特徵。

由於已知卷積核大小會影響其感受域，可以透過下式計算感受域長度：

$$R = 1 + 2 \cdot (k - 1) \cdot \sum_i d_i \quad (6.2)$$

其中 R 代表感受域大小， k 表示捲積核大小， d_i 表示在第 i 個殘差區塊中的擴張捲積的擴張大小。

根據不同卷積核大小算出各自的感受域並畫成圖 6.2，可以發現當感受域大於輸入時間長度（ $N = 200$ ）時，模型的誤差顯著下降。這表示為了使模型性能提升，要先確保感受域的長度足以覆蓋整個輸入資料長度，這與 Bai 等人的研究結果相似 [4]。

綜合考慮卷積核大小對模型性能的影響，本研究後續使用的卷積核大小為 8。除了在測試集中有最小誤差能夠有效捕捉敲擊回音訊號特徵外，也看到過大的卷

積核的感受域過大，可能會考慮過多不相關的資訊，反而使得模型表現下降。

Residual Block: 5, Filter: 25		
Kernel Size	Receptive Field	MAE (cm)
2	63	4.206
3	125	3.647
4	187	1.343
5	249	0.143
6	311	0.292
7	373	0.228
8	435	0.115
10	559	0.139
12	683	0.366

表 6.5 卷積核大小




圖 6.2 不同卷積核大小的模型表現

卷積核數量

以下探討不同卷積核數量對模型表現的影響。從圖 6.3 可以看出，誤差隨著卷積核數量的增加而誤差有下降的趨勢。當卷積核數量過少時，測試誤差會有劇烈波動，但隨著卷積核數量越大，測試誤差逐漸趨於穩定。這說明在適當增加卷積核數量後，模型的表現達到了一個平衡點，繼續增加卷積核數量對模型效能的提升有限。

這一結果與其他研究中的結論類似 [26]，增加卷積層的深度與卷積核數量可以提高模型的表現，但隨著參數的增加，效能提升會逐漸減緩。此外，適當的卷積核數量不僅可以捕捉到足夠的特徵信息，同時也能避免過度擬合的風險，這對於模型的泛化能力至關重要。

因此本研究後續使用的卷積核數量仍是 25，除了在測試集有最小深度誤差，同時可以減少計算成本與訓練時間。經過敲擊回音訊號測試集的修正，本研究使用 TCN 模型如圖 6.4 修改為 5 個殘差區塊、卷積核大小 8 且卷積核數量 25。

Residual Block: 5, Kernel Size: 8	
Filter	MAE (cm)
20	1.076
25	0.115
30	0.939
35	0.811
40	1.561
45	0.361
50	0.276
60	0.323
70	0.378
80	0.231
90	0.153

表 6.6 卷積核數量




圖 6.3 不同卷積核數量的模型表現




圖 6.4 使用敲擊回音訊號測試集修改之 TCN 模型

6.1.3 雜訊影響

在先前的討論所使用的訓練集與測試集都是無雜訊的數值模擬訊號，然而實際應用中，實驗訊號通常會包含一定比例的雜訊如圖 6.5 所示。因此在訓練集中加入雜訊進行訓練，並比較不同程度雜訊測試集的模型表現，以判斷雜訊對模型的影響。其中加入雜訊的方法是以指定範圍隨機選取的標準差生成高斯分布的雜訊加入到資料集訊號中。

從圖 6.6 可以看到，當訓練時沒有加入任何雜訊，模型在測試集上的表現隨著雜訊的增加會顯著下降，說明未加入雜訊訓練的模型缺乏穩定性。隨著訓練集加入的雜訊比例增加，模型對雜訊的穩定性變高，不容易受到影響，能在實際應用上更好的對抗雜訊的干擾。

也可以再從圖 6.6 發現，訓練集加入最大雜訊標準差 3% 時，模型在所有測試雜訊比例下的表現較好，這表示加入適當比例的雜訊能夠提高模型的穩定性，同時在無雜訊的情況下也不會表現太差。而當訓練集加入最大雜訊標準差 10% 時，雖然模型整體對雜訊的影響最為緩和，但在較小的雜訊下表現會較差，這表明過多的雜訊可能會影響模型在低雜訊環境下的表現。因此根據實驗結果，本研究認為加入最大雜訊標準差 3% 進行訓練是提高模型穩定性的最佳選擇。




圖 6.5 實際實驗訊號的雜訊




圖 6.6 訓練資料加入雜訊對不同雜訊大小的測試結果



6.1.4 時間原點影響

在實驗訊號的前處理中，需要自行判斷標註時間原點，但實際上選取的時間原點如圖 6.7 可能多少會有誤差。因此本研究在訓練集加入不同平移時間改變時間原點，並測試在不同時間原點下的模型表現能力。

從圖 6.8 可以看到當訓練集沒有加入時間平移時，模型在測試有時間平移的訊號表現會顯著下降，這說明模型對時間平移的穩定性不足。但隨著訓練集加入時間平移後，模型對時間平移的穩定性顯著提高，能更好地處理時間平移帶來的影響。

因此可以得到以下結論，只要訓練集加入時間平移就能大幅提高模型的穩定性。由於本研究計算模擬訊號與實驗訊號的時間原點到表面波最小值的平均時間差異約為 $10 \sim 20\mu\text{s}$ 。因此選擇加入最大時間平移 $30\mu\text{s}$ 是足夠提升模型的穩定性和表現。




圖 6.7 模擬訊號與實驗訊號時間原點差異




圖 6.8 訓練資料加入平移對不同平移大小的測試結果

6.1.5 鋼珠直徑影響

到目前為止，模型使用的訓練集是根據裂縫深度選擇了不同直徑的鋼珠敲擊。為了得知模型在使用不同鋼珠直徑敲擊是否也能有好的表現能力，因此使用 4, 6, 10mm 鋼珠敲擊試體厚度 30cm 的各深度裂縫。結果顯示，模型在訓練集中所包含的鋼珠直徑上表現良好，但在其他鋼珠直徑下的深度預測誤差較大，顯示出模型在不同鋼珠大小敲擊下缺乏泛化能力。

如圖 6.12 所示，雖然不同直徑鋼珠敲擊訊號經過 FFT 轉換後的頻率域特徵可能相似，但在時間域上，不同鋼珠的反射和繞射特徵有顯著差異。這表示僅僅使用單一直徑鋼珠的訊號可能不足以使模型在不同直徑鋼珠下具有良好的泛化能力。

為了提高模型的泛化能力，在訓練集中加入更多樣化的訊號是必要且重要的。因此，在新的訓練集中各個深度均使用 4, 6, 10mm 三種不同直徑鋼珠的敲擊訊號，此做法能夠大幅改善模型的表現效果，使其能夠更好的應對不同鋼珠直徑下的訊號。





圖 6.9 4mm 鋼珠敲擊裂縫深度 6 ~ 16cm 與 18 ~ 26cm 無限平版結果





圖 6.10 6mm 鋼珠敲擊裂縫深度 6 ~ 16cm 與 18 ~ 26cm 無限平版結果





圖 6.11 10mm 鋼珠敲擊裂縫深度 6 ~ 16cm 與 18 ~ 26cm 無限平版結果




圖 6.12 不同直徑鋼珠在裂縫深度 12cm 時間域與頻率域模擬訊號

6.1.6 波速影響

由於本研究的訓練集使用的混凝土材料性質為密度 2300kg/m^3 、楊氏模數 33.1GPa 與柏松比 0.2 ，透過式 (2.1) 所計算出縱波波速為 3998m/s 。然而在實際應用中，不同試體的材料性質可能有所差異，不僅導致縱波波速與位移訊號產生變化，更從而影響模型的準確性。

如表 6.7 所示的三種混凝土試體，其波速分別為 3998m/s 、 3768m/s 和 4216m/s 。由於縱波波速的不同，因此需要對敲擊回音訊號進行波速修正。本研究藉由式 (6.3) 調整訊號時間來修正波速，使其與訓練集訊號保持一致，改善不同波速對模型的差異。結果如圖 6.13 所示，可以有效的消除不同波速之間的差異。

$$t' = t \cdot \frac{C_p}{C_{p_train}} \quad (6.3)$$

其中 t' 是調整後的時間， t 是原始的時間， C_p 是試體縱波波速， C_{p_train} 是訓練集使用的試體縱波波速。

表 6.7 不同波速材料性質

材料	密度 (kg/m ³)	楊氏模數 (GPa)	柏松比	縱波波速 (m/s)
混凝土-1	2300	33.1	0.2	3998
混凝土-2	1800	25	0.2	3768
混凝土-3	2500	50	0.2	4216




圖 6.13 修正混凝土波速前與後

6.1.7 模型泛用性測試

根據前面討論，本研究選擇使用所有鋼珠直徑敲擊訊號作為訓練集如表 6.8 所示，並加入最大標準差為表面波振幅 3% 的雜訊，對時間原點作最大 30 μ s 之平移。在測試集中，加入比訓練集更多的最大標準差為表面波振幅 5% 的雜訊，同時對時間原點作最大 30 μ s 之平移。

表 6.8 使用所有鋼珠直徑之訓練集資訊

訓練集	反射條件	試體厚度 H(cm)	裂縫深度 D(cm)	鋼珠直徑 (mm)	訊號數量
2	半無限域	30	6, 8, 10, 12, 14, 16	4, 6, 10	6600
			18, 20, 22, 24, 26		

內插深度

由於本研究在訓練集訓練的裂縫深度為 6, 8, 10, 12, 14, 16, 18, 20, 22, 24, 26cm。為了進一步驗證模型的泛用性，在測試集中選擇了訓練集深度範圍內的

連續深度 6 ~ 26cm 做內插深度的測試如表 6.9 所示，其中包含了各種不同厚度試體。

圖 6.14 至圖 6.16 不同試體厚度下的測試結果，能看到 TCN 模型在內插深度的表現相對穩定且準確。這表明模型具有良好的泛化能力，能夠在不同試體條件下有效檢測裂縫深度。這些結果進一步證實了模型的穩定性與適應性，能夠在實際應用中應對多種測試條件。

表 6.9 內插深度測試集資訊

測試集	反射條件	試體厚度 H(cm)	裂縫深度 D(cm)	鋼珠直徑 (mm)	訊號數量
1	無限平板	30	6 ~ 16	6	4200
			17 ~ 26	10	
2		20	6 ~ 16	6	2400
3		6 ~ 16	—	6	4200
		17 ~ 26		10	




圖 6.14 試體厚度 30cm 裂縫深度 6 ~ 26cm 無限平板結果 (MAE: 0.152)




圖 6.15 試體厚度 20cm 裂縫深度 6 ~ 17cm 無限平板結果 (MAE: 0.138)




圖 6.16 試體厚度 6 ~ 26cm 無裂縫無限平版結果 (MAE: 0.347)

外插深度

另外，也選擇了厚度 30cm 試體，以裂縫深度 4cm 與無裂縫分別代表 4cm 與 30cm 外插深度測試訊號，如表 6.10 所示。

從圖 6.17 與圖 6.18 的測試結果中可以看到，模型在外插裂縫深度的預測結果明顯偏離了實際深度。深度 4cm 的裂縫被模型預測為接近深度 6cm 的裂縫，而深度 30cm 的無裂縫試體被模型預測為接近深度 26cm 的裂縫。

由於深度學習模型在進行外插時本來就有難度，難以跳脫訓練數據的界限進行準確預測。本研究在訓練時僅使用了深度範圍在 6cm 到 26cm 之間的訊號數據，因此在面對超出此範圍的數據時，模型無法準確預測深度，而是傾向於預測為接近訓練數據範圍的邊界值。另外從圖 6.19 猜測模型可能將 4cm 深度的裂縫預測為 6cm，是因為 4cm 深度的時間域訊號與訓練集中 6cm 深度的時間域訊號最相似。同樣的在 30cm 深度的無裂縫試體被預測為接近 26cm 也可能是同樣的原因。

模型在外插部分的泛化能力不足，這意味著模型在面對未知深度時無法提供可靠的預測。因此如果需要模型判讀更廣泛深度範圍的深度，需要加入這些深度訊號進入訓練集中訓練，才能在實際應用中更好地應對不同的測試條件和深度範圍。




表 6.10 外插深度測試集資訊

測試集	反射條件	試體厚度 H(cm)	裂縫深度 D(cm)	鋼珠直徑 (mm)	訊號數量
1	無限平板	30	4	6	200
3			—	10	200




圖 6.17 試體厚度 30cm 裂縫深度 4cm 無限平板結果 (MAE: 2.021)




圖 6.18 試體厚度 30cm 無裂縫無限平板結果 (MAE: 3.630)





圖 6.19 裂縫深度 4cm 與無裂縫厚度 30cm 與其他深度比較



有限平版

從前面的討論可以知道，在訓練過的深度範圍內，皆可以獲得較低的誤差深度，然而以上皆在無限平板的反射條件下。因此，本研究使用有限平版試體厚度 20cm，內部有水平裂縫深度 6cm 與 10cm 以及傾斜裂縫深度 12-8cm 與 14-6cm，對試體整體敲擊並觀察側邊反射對訊號影響，測試資料如表 6.11 所示。

從圖 6.20 至圖 6.27 的結果可以觀察發現，模型在預測裂縫邊緣及試體邊界處的誤差值較大。在裂縫邊緣處，由於敲擊與接收點都恰好都在裂縫邊緣，波傳遞至裂縫深度時可能會進一步繞射至底部，造成預測深度誤差增加。在試體邊界處，在距離邊界約 4cm 處開始受到邊界反射影響，時間長度 $T \approx \frac{0.04 \cdot 2}{4000} = 20\mu s$ 就開始受到邊界影響，反射波很早就對訊號產生重大干擾，導致模型預測結果誤差增大。如果忽略最外圍嚴重受到邊界反射的極端的測點訊號，整體的深度誤差是在可以接受的範圍內。

表 6.11 有限平版測試集資訊

測試集	反射條件	試體厚度 H(cm)	裂縫深度 D(cm)	鋼珠直徑 (mm)	訊號數量
4	有限平版	20	6	6	361
			10		361
			12-8		361
			14-6		361




圖 6.20 試體厚度 20cm 裂縫深度 6cm 有限平版整體結果




圖 6.21 試體厚度 20cm 裂縫深度 10cm 有限平版整體結果




圖 6.22 試體厚度 20cm 裂縫深度 6cm 有限平版截面結果




圖 6.23 試體厚度 20cm 裂縫深度 10cm 有限平版截面結果




圖 6.24 試體厚度 20cm 裂縫深度 12-8cm 有限平版整體結果




圖 6.25 試體厚度 20cm 裂縫深度 14-6cm 有限平版整體結果




圖 6.26 試體厚度 20cm 裂縫深度 14-6cm 有限平版截面結果




圖 6.27 試體厚度 20cm 裂縫深度 14-6cm 有限平版截面結果



6.2 實驗訊號結果

在實驗訊號上，首先討論前處理濾波對實驗訊號的影響，接著使用其他時間序列也會使用的資料增強方法，最後呈現這些實驗訊號的結果。為了避免實驗訊號與其他反射干擾，因此使用的測試集訊號為靠近裂縫中心的訊號，測試的實驗資訊如表 6.12 所示。

表 6.12 裂縫中心附近實驗測試集資訊

測試集	反射條件	試體厚度 H(cm)	裂縫深度 D(cm)	鋼珠直徑 (mm)	訊號數量
5	實驗試體	20	6	6	25
			10		25
			12		50
			12-8		25
			14-6		25
		50	25	10	50

6.2.1 濾波方式比較

對於濾波方式本研究採取平均濾波器與巴特沃斯濾波器兩種方法，與沒有特別經過濾波的訊號比較。本研究對取樣時距 $1\mu s$ 的原始實驗訊號做濾波處理，取樣頻率為 $1,000,000\text{Hz}$ ， $50,000\text{Hz}$ 的截止頻率是能夠有效地減少高頻噪聲的影響。另外對平均濾波器的窗口大小設定為 $5\mu s$ ($N=5$) 也一定程度對雜訊有改善。但是從表 6.13 可以看到，不管有沒有做過濾波處理，對模型預測深度而言沒有顯著的差別。這可能是由於已經在訓練時加入了一定比例的雜訊，因此模型對實際實驗中的高頻噪聲具有良好的穩定性。

雖然有無使用濾波對實驗訊號影響不大，但由於最後在使用平均濾波器時有最低的深度誤差，因此後續對實驗訊號採用平均濾波器處理。

表 6.13 濾波方法對實驗訊號結果

Depth (cm)	MAE (cm)		
	None	Averaging (5 μ s)	Butterworth* (50000Hz)
6	0.519	0.534	0.551
10	0.436	0.431	0.421
12	0.399	0.399	0.432
12-8	0.437	0.437	0.408
14-6	0.645	0.595	0.594
25	0.547	0.545	0.545
Average	0.491	0.486	0.491



6.2.2 資料增強比較

在先前模擬訊號中，已經討論了雜訊和平移對模型的影響。在別的時間序列資料上也有使用過不同的資料增強方法，亦嘗試使用這些資料增強方法來是否能改善實驗訊號的表現。

本研究在原本的雜訊和平移基礎上，加入了縮放（scaling）、振幅扭曲（magnitude warping）與時間扭曲（time warping）等方法。結果如表 6.14 所示，顯然這些資料增強方法對模型分析實驗訊號的表現並無助益，特別對裂縫較深訊號表現會變差，原因可能是較深裂縫其反射來回次數較少且回音振幅較小，而振幅扭曲與時間扭曲對波型的影響較大，因此導致此結果。

而根據表 6.14 實驗結果，最後還是使用原本有最小深度誤差的雜訊與平移資料增強方法。但在未來還是可以進一步討論不同資料增強方法的組合效果，以進一步提升模型的穩定性和準確性。

表 6.14 資料增強方法對實驗訊號結果

Depth (cm)	MAE (cm)			
	Noising + Sliding	Noising + Sliding + Scaling	Noising + Sliding + Magnitude warping	Noising + Sliding + Time warping
6	0.534	0.658	1.104	0.934
10	0.431	0.471	0.456	0.673
12	0.399	0.511	0.472	0.663
12-8	0.437	0.481	0.521	0.545
14-6	0.595	0.555	0.435	0.786
25	0.545	0.870	1.749	4.666
Average	0.486	0.616	0.870	1.700

6.2.3 實驗結果

裂縫中心訊號

首先是對各個裂縫的較中心處進行敲擊的結果，從圖 6.28 至圖 6.33 的結果可以看到，在不管是淺層裂縫、深層裂縫還是傾斜裂縫，模型的預測結果都相對準確。特別是在淺層裂縫的深度預測上，深度學習模型直接判讀時間域訊號確實能夠改善頻率域所產生的模態混疊問題。




圖 6.28 試體厚度 20cm 裂縫深度 6cm 實驗結果 (MAE: 0.534)




圖 6.29 試體厚度 20cm 裂縫深度 10cm 實驗結果 (MAE: 0.431)




圖 6.30 試體厚度 20cm 裂縫深度 12cm 實驗結果 (MAE: 0.399)




圖 6.31 試體厚度 20cm 裂縫深度 12-8cm 實驗結果 (MAE: 0.437)




圖 6.32 試體厚度 20cm 裂縫深度 14-6cm 實驗結果 (MAE: 0.595)




圖 6.33 試體厚度 50cm 裂縫深度 25cm 實驗結果 (MAE: 0.545)

整體實驗訊號

另外也對試體厚度 20cm，裂縫深度 6cm、10cm、12-8cm 與 14-6cm 進行整體敲擊試驗，其測試資訊如表 6.15。結果為圖 6.34 至圖 6.41，其結果與模擬有限平板的情形類似，在裂縫邊緣處與試體邊界處會有較大的深度誤差，甚至實驗訊號側邊反射的影響範圍比有限平板還要更大一些。由於訓練時使用的都是半無限域無反射訊號，如果在靠近試體邊界處的敲擊訊號會產生較大的反射，這需要透過其他方法來解決。




表 6.15 整體實驗試體測試集資訊

測試集	反射條件	試體厚度 H(cm)	裂縫深度 D(cm)	鋼珠直徑 (mm)	訊號數量
5	實驗試體	20	6	6	361
			10		361
			12-8		361
			14-6		361




圖 6.34 試體厚度 20cm 裂縫深度 6cm 實驗整體結果




圖 6.35 試體厚度 20cm 裂縫深度 10cm 實驗整體結果




圖 6.36 試體厚度 20cm 裂縫深度 6cm 實驗截面結果




圖 6.37 試體厚度 20cm 裂縫深度 10cm 實驗截面結果




圖 6.38 試體厚度 20cm 裂縫深度 12-8cm 實驗整體結果




圖 6.39 試體厚度 20cm 裂縫深度 14-6cm 實驗整體結果




圖 6.40 試體厚度 20cm 裂縫深度 12-8cm 實驗截面結果




圖 6.41 試體厚度 20cm 裂縫深度 14-6cm 實驗截面結果



第七章 結論與未來展望

7.1 結論

本研究主要使用深度學習模型分析敲擊回音時間域訊號，模型之輸入為敲擊回音試驗所量測的前 $320\mu\text{s}$ 時間域訊號，輸出則為反射介面深度。本研究先以有限元素軟體生成內含深度 6.26cm 裂縫之半無限域的敲擊回音訊號，再以無限平板、有限平板模擬訊號及實驗訊號驗證模型的可行性。為了找出最佳模型，本研究對不同模型參數進行了測試與調整。最後，經過數值模擬訊號與實驗訊號的測試，獲得了以下結論：

1. 深度學習模型：本研究對 MLP、FCN、ResNet 和 TCN 模型進行比較，測試結果顯示 TCN 模型表現最佳。
2. TCN 模型架構：卷積層的深度過多或過少都無法獲得良好的結果，卷積層太少無法有效提取訊號特徵，過多則會造成過擬合現象。卷積核大小直接影響感知域，選擇卷積核大小時需要確保感知域至少大於輸入長度以獲得較好的結果。卷積核數量對模型表現影響顯著，隨著卷積核數量的增加，模型表現逐漸趨於穩定。
3. 模型穩定性：在訓練集中加入最大 3% 的雜訊以及最大 $30\mu\text{s}$ 的時間平移，有助於提升模型對分析有雜訊與時間平移的模擬及實驗訊號的穩定性。此

外，增加訓練集訊號所涵蓋的敲擊源鋼珠尺寸，對模擬與實驗結果的改善效果非常顯著。



4. 模擬訊號結果：由於訓練集的裂縫深度範圍 6 至 26cm，故 TCN 模型在辨識 6 ~ 26cm 內插深度裂縫的表現良好，但對 4cm 和 30cm 的外插深度誤差較大。若未來檢測的試體尺寸更大，則需在訓練集中加入裂縫深度更大的訊號進行訓練。
5. 實驗訊號結果：實驗訊號有無使用濾波對結果影響不大，訓練資料中加入雜訊能有效抵抗高頻雜訊干擾，提升模型穩定性。其他資料增強方法對模型分析實驗訊號的表現並無助益，尤其是振幅扭曲與時間扭曲反而會導致模型在深層裂縫表現變差。TCN 模型對分析裂縫深度 6, 10, 12, 12-8, 14-6 及 25cm 的實驗訊號均表現良好，顯示本研究方法的可行性。

綜合上面所述，本研究發展之 TCN 模型確能有效地分析敲擊回音時間域訊號，尤其對淺層裂縫的偵測更是遠優於頻率域方法，為混凝土結構之非破壞檢測中提供了一種全新且有效的方法。


7.2 未來展望

本研究僅使用半無限域訊號作為訓練集，雖然能夠在沒有其他邊界反射下表現良好。但未來如需判讀更深的裂縫，將需要增加輸入訊號的長度，這可能會增加更強的反射和繞射干擾訊號，從而使對深層裂縫的判讀變得更加困難。因此，未來的研究應考慮如何有效地處理這些干擾，以提高對深層裂縫的深度判讀準確性。



參考文獻

- [1] J. D. Achenbach. Wave Propagation in Elastic Solids. Elsevier Science Publishing Co. Inc., 2 edition, 1973. ISBN:9780720423679.
- [2] G. An. The Effects of Adding Noise During Backpropagation Training on a Generalization Performance. Neural Computation, 8(3):643–674, 1996. DOI:10.1162/neco.1996.8.3.643.
- [3] A. Bagnall, J. Lines, A. Bostrom, J. Large, and E. Keogh. The great time series classification bake off: a review and experimental evaluation of recent algorithmic advances. Data Mining and Knowledge Discovery, 31:606–660, 2017. DOI:10.1007/s10618-016-0483-9.
- [4] S. Bai, J. Z. Kolter, and V. Koltun. An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv preprint, 2018. arXiv:1803.01271.
- [5] Y. Bengio, P. Simard, and P. Frasconi. Learning long-term dependencies with gradient descent is difficult. IEEE transactions on Neural Networks, 5(2):157–166, 1994. DOI:10.1109/72.279181.
- [6] C. M. Bishop. Training with Noise is Equivalent to Tikhonov Regularization. Neural Computation, 7(1):108–116, 1995. DOI:10.1162/neco.1995.7.1.108.

- 
- [7] N. J. Carino, M. Sansalone, and N. N. Hsu. Flaw detection in concrete by frequency spectrum analysis of impact-echo waveforms. International Advances in Nondestructive Testing, 12:117–146, 1986.
- [8] Y. Chen, E. Keogh, B. Hu, N. Begum, A. Bagnall, A. Mueen, and G. Batista. The UCR Time Series Classification Archive, July 2015. URL:www.cs.ucr.edu/~eamonn/time_series_data/.
- [9] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio. Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling. arXiv preprint, 2014. arXiv:1412.3555.
- [10] C. Colla and R. Lausch. Influence of source frequency on impact-echo data quality for testing concrete structures. NDT & E International, 36(4):203–213, 2003. DOI:10.1016/S0963-8695(02)00062-2.
- [11] H. A. Dau, A. Bagnall, K. Kamgar, C.-C. M. Yeh, Y. Zhu, S. Gharghabi, C. A. Ratanamahatana, and E. Keogh. The UCR time series archive. IEEE/CAA Journal of Automatica Sinica, 6(6):1293–1305, 2019. DOI:10.1109/JAS.2019.1911747.
- [12] Y. N. Dauphin, A. Fan, M. Auli, and D. Grangier. Language Modeling with Gated Convolutional Networks. In Proceedings of the 34th International Conference on Machine Learning, pages 933–941, 2017. URL:<https://proceedings.mlr.press/v70/dauphin17a.html>.
- [13] W. Goldsmith. Impact: The Theory and Physical Behaviour of Colliding Solids. Edward Arnold, 1960. ISBN:9780486401928.
- [14] K. He, X. Zhang, S. Ren, and J. Sun. Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification. In Proceedings of the

2015 IEEE International Conference on Computer Vision, pages 1026–1034, 2015.

DOI:10.1109/ICCV.2015.1239.



- [15] K. He, X. Zhang, S. Ren, and J. Sun. Deep Residual Learning for Image Recognition. In Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition, pages 770–778, 2016. DOI:10.1109/CVPR.2016.90.

- [16] H. Hertz. Miscellaneous papers. Macmillan Publishers, 1896.

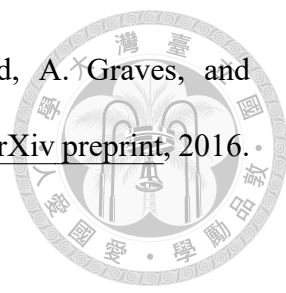
- [17] S. Hochreiter and J. Schmidhuber. Long Short-Term Memory. Neural Computation, 9(8):1735–1780, 1997. DOI:10.1162/neco.1997.9.8.1735.

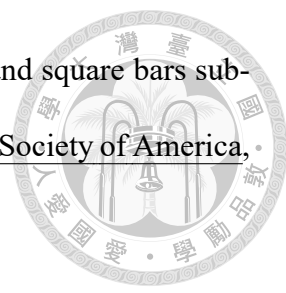
- [18] S. Ioffe and C. Szegedy. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. In Proceedings of the 32nd International Conference on Machine Learning, pages 448–456, 2015. URL:<https://proceedings.mlr.press/v37/ioffe15.html>.

- [19] H. Ismail Fawaz, G. Forestier, J. Weber, L. Idoumghar, and P.-A. Muller. Deep learning for time series classification: a review. Data Mining and Knowledge Discovery, 33(4):917–963, 2019. DOI:10.1007/s10618-019-00619-1.


- [20] H. Ismail Fawaz, B. Lucas, G. Forestier, C. Pelletier, D. F. Schmidt, J. Weber, G. I. Webb, L. Idoumghar, P.-A. Muller, and F. Petitjean. InceptionTime: Finding AlexNet for time series classification. Data Mining and Knowledge Discovery, 34(6):1936–1962, 2020. DOI:10.1007/s10618-020-00710-y.

- [21] B. K. Iwana and S. Uchida. An empirical survey of data augmentation for time series classification with neural networks. PLOS One, 16(7):e0254841, 2021. DOI:10.1371/journal.pone.0254841.


- 
- [22] N. Kalchbrenner, L. Espeholt, K. Simonyan, A. v. d. Oord, A. Graves, and K. Kavukcuoglu. Neural Machine Translation in Linear Time. arXiv preprint, 2016. arXiv:1610.10099.
- [23] D. P. Kingma and J. Ba. Adam: A Method for Stochastic Optimization. arXiv preprint, 2014. arXiv:1412.6980.
- [24] A. Krizhevsky, I. Sutskever, and G. E. Hinton. ImageNet Classification with Deep Convolutional Neural Networks. In Proceedings of the 25th International Conference on Neural Information Processing Systems, pages 1097–1105, 2012. URL:https://papers.nips.cc/paper_files/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html.
- [25] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner. Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11):2278–2324, 1998. DOI:10.1109/5.726791.
- [26] Y. Li, L. Xiao, H. Wei, D. Li, and X. Li. A Comparative Study of LSTM and Temporal Convolutional Network Models for Semisubmersible Platform Wave Runup Prediction. Journal of Offshore Mechanics and Arctic Engineering, 147(1):011202, 2025. DOI:10.1115/1.4063266.
- [27] C. C. Lin, P. L. Liu, and P. L. Yeh. Application of empirical mode decomposition in the impact-echo test. NDT & E International, 42(7):589–598, 2009. DOI:10.1016/j.ndteint.2009.03.003.
- [28] M. Lin, Q. Chen, and S. Yan. Network In Network. arXiv preprint, 2013. arXiv:1312.4400.

- 
- [29] Y. Lin and M. Sansalone. Transient response of thick circular and square bars subjected to transverse elastic impact. The Journal of the Acoustical Society of America, 91(2):885–893, 1992. DOI:10.1121/1.402494.
- [30] Y. Lin and M. Sansalone. Detecting Flaws in Concrete Beams and Columns Using the Impact-Echo Method. Materials Journal, 89(4):394–405, 1992. DOI:10.14359/2579.
- [31] B. Liu, Z. Zhang, and R. Cui. Efficient Time Series Augmentation Methods. In 2020 13th International Congress on Image and Signal Processing, BioMedical Engineering and Informatics, pages 1004–1009, 2020. DOI:10.1109/CISP-BMEI51763.2020.9263602.
- [32] J. Long, E. Shelhamer, and T. Darrell. Fully convolutional networks for semantic segmentation. In Proceedings of the 2015 IEEE Conference on Computer Vision and Pattern Recognition, pages 3431–3440, 2015. DOI:10.1109/CVPR.2015.7298965.
- [33] V. Nair and G. E. Hinton. Rectified linear units improve restricted boltzmann machines. In Proceedings of the 27th International Conference on Machine Learning, pages 807–814, 2010. URL:<https://dl.acm.org/doi/10.5555/3104322.3104425>.
- [34] R. Pascanu, T. Mikolov, and Y. Bengio. On the difficulty of training recurrent neural networks. In Proceedings of the 30th International Conference on Machine Learning, pages 1310–1318, 2013. URL:<https://proceedings.mlr.press/v28/pascanu13.html>.
- [35] M. A. Pimentel, P. H. Charlton, and D. A. Clifton. Probabilistic Estimation of Respi-

ratory Rate from Wearable Sensors. Wearable Electronics Sensors, pages 241–262, 2015. DOI:10.1007/978-3-319-18191-2_10.



- [36] M. A. Pimentel, A. E. Johnson, P. H. Charlton, D. Birrenkott, P. J. Watkinson, L. Tarassenko, and D. A. Clifton. Toward a Robust Estimation of Respiratory Rate From Pulse Oximeters. IEEE Transactions on Biomedical Engineering, 64(8):1914–1923, 2016. DOI:10.1109/TBME.2016.2613124.
- [37] D. Pratt and M. Sansalone. Impact-Echo Signal Interpretation Using Artificial Intelligence. Materials Journal, 89(2):178–187, 1992. DOI:10.14359/2265.
- [38] F. Rosenblatt. The perceptron: A probabilistic model for information storage and organization in the brain. Psychological Review, 65:386–408, 1958. DOI:10.1037/h0042519.
- [39] D. E. Rumelhart, G. E. Hinton, and R. J. Williams. Learning representations by back-propagating errors. Nature, 323:533–536, 1986. DOI:10.1038/323533a0.
- [40] T. Salimans and D. P. Kingma. Weight Normalization: A Simple Reparameterization to Accelerate Training of Deep Neural Networks. Proceedings of the 29th International Conference on Neural Information Processing Systems, pages 901–909, 2016. URL:<https://proceedings.neurips.cc/paper/2016/hash/ed265bc903a5a097f61d3ec064d96d2e-Abstract.html>.
- [41] M. Sansalone and N. J. Carino. Impact-Echo: A Method for Flaw Detection in Concrete Using Transient Stress Waves. NBSIR 86-3452, National Bureau of Standards, 1986. DOI:10.6028/NBS.IR.86-3452.
- [42] K. Simonyan and A. Zisserman. Very Deep Convolutional Networks for Large-Scale Image Recognition. arXiv preprint, 2014. arXiv:1409.1556.

- 
- [43] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. The Journal of Machine Learning Research, 15(1):1929–1958, 2014. URL:www.jmlr.org/papers/v15/srivastava14a.html.
- [44] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich. Going deeper with convolutions. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 1–9, 2015. DOI:10.1109/CVPR.2015.7298594.
- [45] C. W. Tan, C. Bergmeir, F. Petitjean, and G. I. Webb. Time series extrinsic regression. Data Mining and Knowledge Discovery, 35(3):1032–1060, 2021. DOI:10.1007/s10618-021-00745-9.
- [46] T. T. Um, F. M. Pfister, D. Pichler, S. Endo, M. Lang, S. Hirche, U. Fietzek, and D. Kulić. Data augmentation of wearable sensor data for parkinson’s disease monitoring using convolutional neural networks. In Proceedings of the 19th ACM International Conference on Multimodal Interaction, pages 216–220, 2017. DOI:10.1145/3136755.3136817.
- [47] A. Van Den Oord, S. Dieleman, H. Zen, K. Simonyan, O. Vinyals, A. Graves, N. Kalchbrenner, A. Senior, K. Kavukcuoglu, et al. WaveNet: A Generative Model for Raw Audio. arXiv preprint, 2016. arXiv:1609.03499.
- [48] A. Waibel, T. Hanazawa, G. Hinton, K. Shikano, and K. Lang. Phoneme recognition using time-delay neural networks. IEEE Transactions on Acoustics, Speech, and Signal Processing, 37(3):328–339, 1989. DOI:10.1109/29.21701.
- [49] Z. Wang, W. Yan, and T. Oates. Time series classification from scratch with deep

- neural networks: A strong baseline. In 2017 International Joint Conference on Neural Networks, pages 1578–1585, 2017. DOI:10.1109/IJCNN.2017.7966039.
- [50] Q. Wen, L. Sun, F. Yang, X. Song, J. Gao, X. Wang, and H. Xu. Time Series Data Augmentation for Deep Learning: A Survey. arXiv preprint, 2020. arXiv:2002.12478.
- [51] P. L. Yeh and P. L. Liu. Application of the wavelet transform and the enhanced fourier spectrum in the impact echo test. NDT & E International, 41(5):382–394, 2008. DOI:10.1016/j.ndteint.2008.01.002.
- [52] M. D. Zeiler. ADADELTA: An Adaptive Learning Rate Method. arXiv preprint, 2012. arXiv:1212.5701.
- [53] 張 亘. 應用深度學習判讀裂縫與鋼筋之敲擊回音小波譜. 國立臺灣大學應用力學研究所碩士論文, 2023. DOI:10.6342/NTU202303674.
- [54] 曾勁凱. 以卷積自動編碼器進行敲擊回音深度頻譜斷層掃描之裂縫偵測. 國立臺灣大學應用力學研究所碩士論文, 2024. DOI:10.6342/NTU202400498.
- [55] 林 昀 儒. 以 CNN 自動編碼器辨識敲擊回音試驗之異常訊號. 國立臺灣大學應用力學研究所碩士論文, 2020. DOI:10.6342/NTU202002895.
- [56] 謝承展. 以機器學習與主成分分析進行敲擊回音本質模態函數之分類. 國立臺灣大學應用力學研究所碩士論文, 2022. DOI:10.6342/NTU202203237.
- [57] 陳 柏 合. 以深度學習判別鋼筋與裂縫之敲擊回音雙譜. 國立臺灣大學應用力學研究所碩士論文, 2021. DOI:10.6342/NTU202104225.
- [58] 陳 源 泰. 以深度學習方法判讀敲擊回音時頻圖. 國立臺灣大學應用力學研究所碩士論文, 2021. DOI:10.6342/NTU202104177.